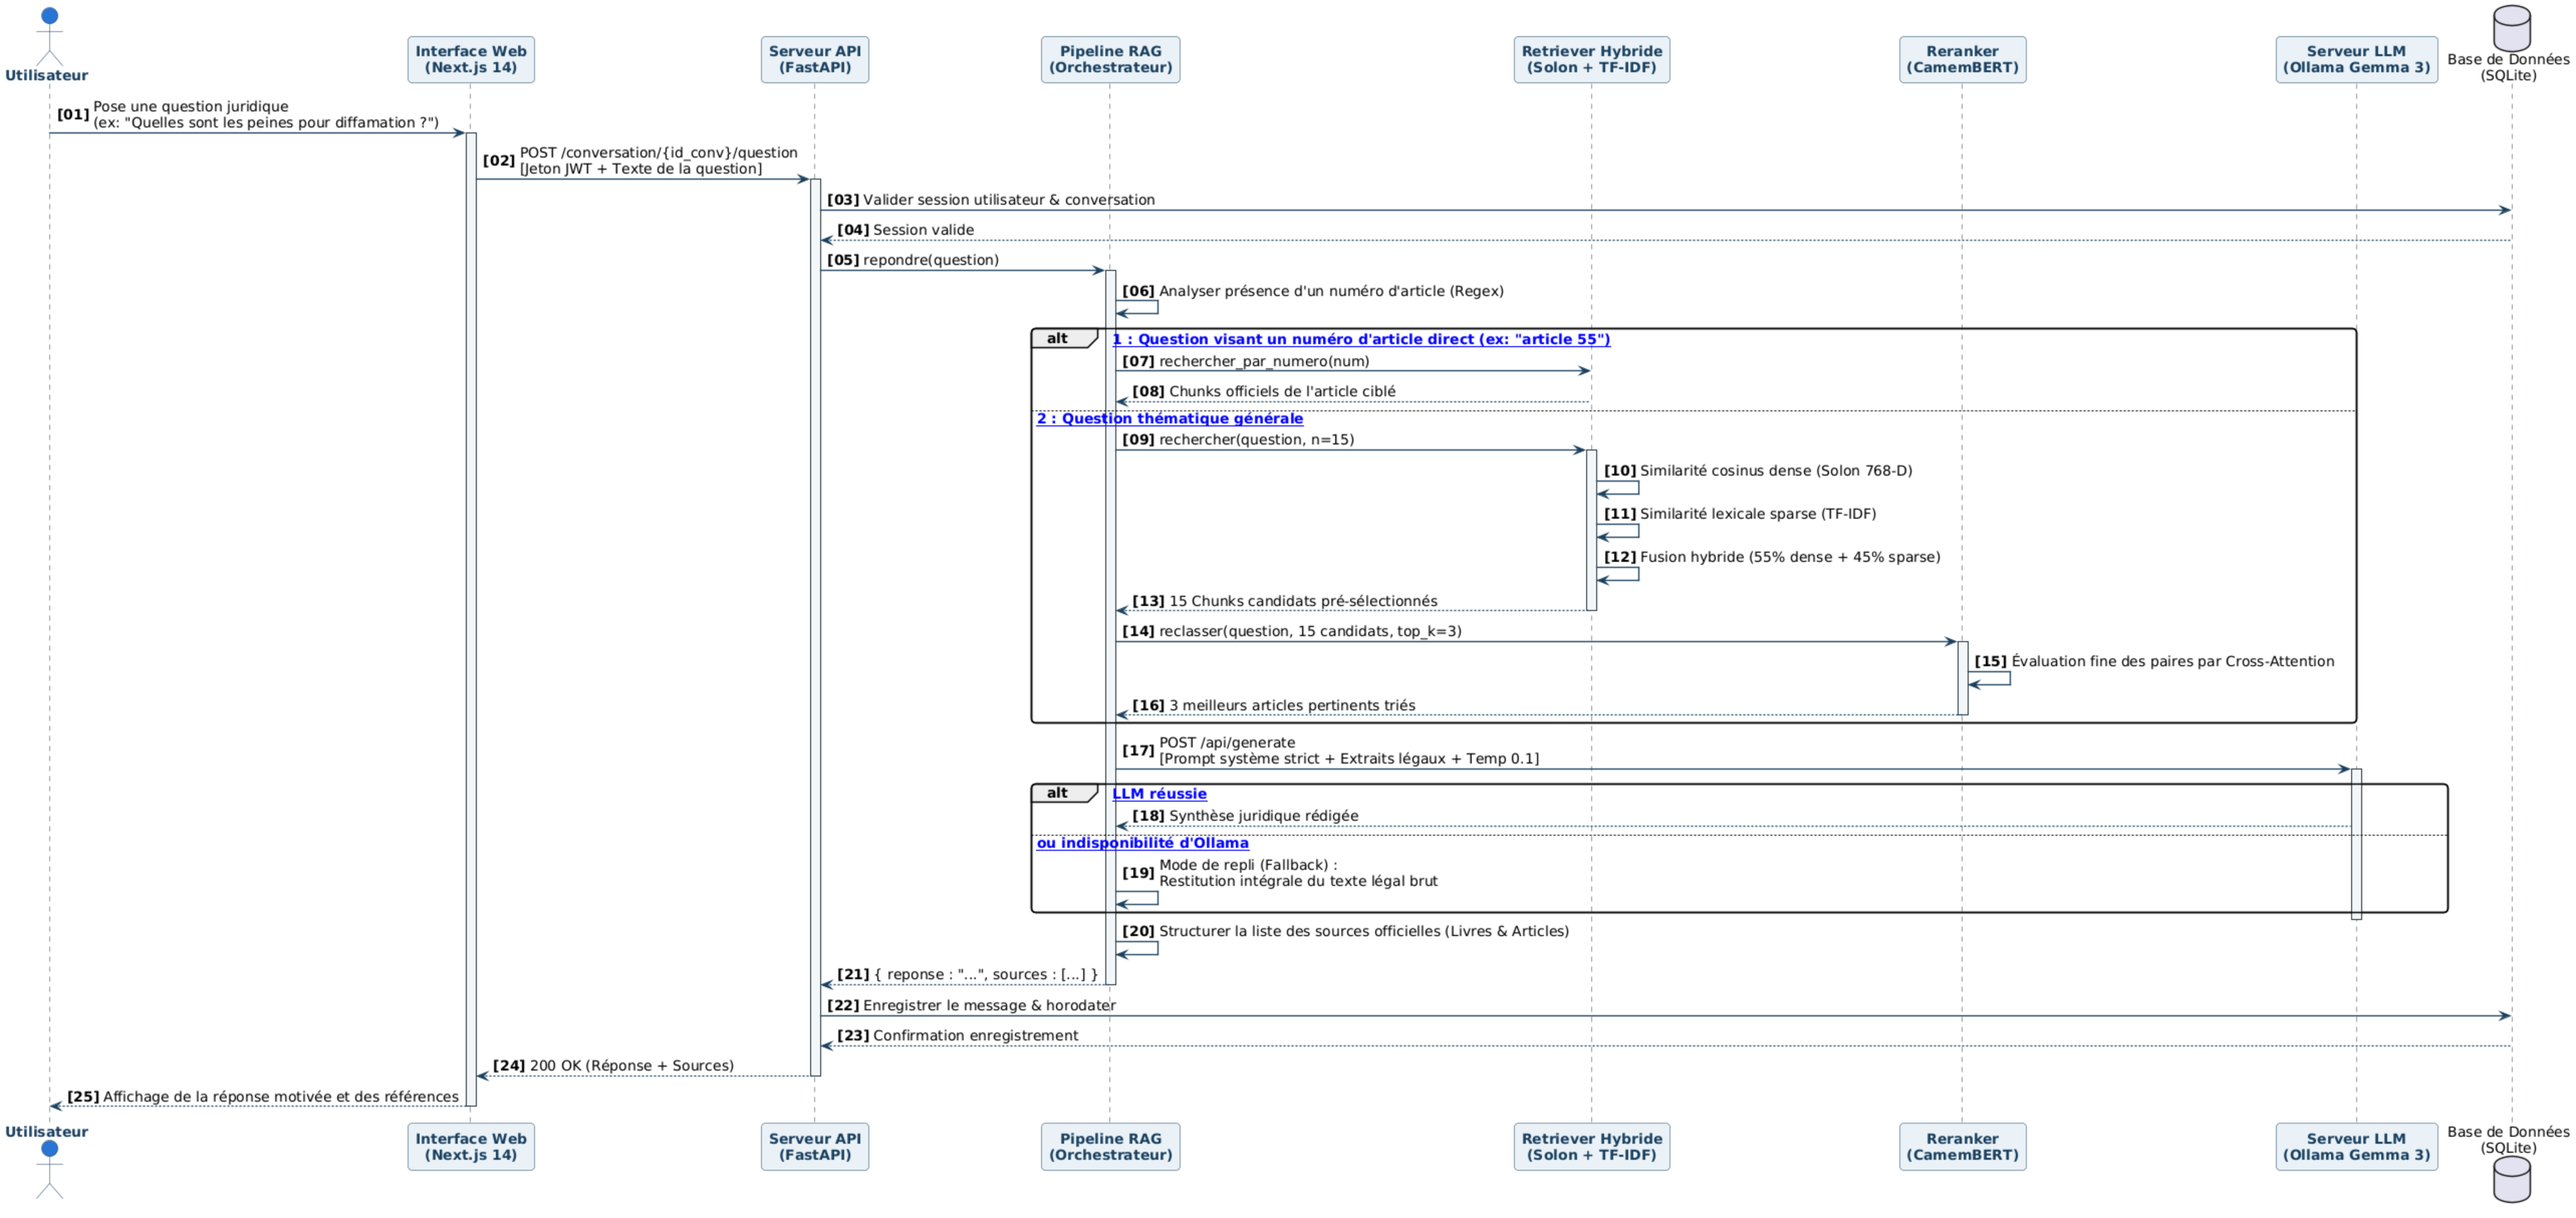

Utilisateur
Interface Web (Next.js 14)
Serveur API (FastAPI)
Pipeline RAG (Orchestrateur)
Retriever Hybride (Solon + TF-IDF)
Reranker (CamemBERT)
Serveur LLM (Ollama Gemma 3)
Base de Données (SQLite)
[01] Pose une question juridique (ex: "Quelles sont les peines pour diffamation ?")
[02] POST /conversation/{id_conv}/question [Jeton JWT + Texte de la question]
[03] Valider session utilisateur & conversation
[04] Session valide
[05] repondre(question)
[06] Analyser présence d'un numéro d'article (Regex)
alt
1 : Question visant un numéro d'article direct (ex: "article 55")
[07] rechercher_par_numero(num)
[08] Chunks officiels de l'article ciblé
2 : Question thématique générale
[09] rechercher(question, n=15)
[10] Similarité cosinus dense (Solon 768-D)
[11] Similarité lexicale sparse (TF-IDF)
[12] Fusion hybride (55% dense + 45% sparse)
[13] 15 Chunks candidats pré-sélectionnés
[14] reclasser(question, 15 candidats, top_k=3)
[15] Évaluation fine des paires par Cross-Attention
[16] 3 meilleurs articles pertinents triés
[17] POST /api/generate [Prompt système strict + Extraits légaux + Temp 0.1]
alt
LLM réussie
[18] Synthèse juridique rédigée
ou indisponibilité d'Ollama
[19] Mode de repli (Fallback) : Restitution intégrale du texte légal brut
[20] Structurer la liste des sources officielles (Livres & Articles)
[21] { reponse : "...", sources : [...] }
[22] Enregistrer le message & horodater
[23] Confirmation enregistrement
[24] 200 OK (Réponse + Sources)
[25] Affichage de la réponse motivée et des références