

RÉPUBLIQUE DU BÉNIN
MINISTÈRE DE L'ENSEIGNEMENT SUPÉRIEUR
ET DE LA RECHERCHE SCIENTIFIQUE

UNIVERSITÉ D'ABOMEY-CALAVI

INSTITUT DE FORMATION ET DE RECHERCHE EN INFORMATIQUE

BP 526 Cotonou Tel : +229 21 14 19 88
http://www.ifri-uac.net Courriel : contact@ifri.uac.bj



MÉMOIRE

pour l'obtention du

Diplôme de Licence en Informatique

Option : Génie Logiciel

Présenté par :
Yélian Joanès Domicov **AZON**

Conception d'un assistant conversationnel intelligent et optimisation des réponses via la génération augmentée de récupération (RAG) et l'apprentissage par renforcement : cas du mentorat virtuel pour l'orientation universitaire au Bénin

Sous la supervision :
Armand **ACCROMBESSI**

Membres du jury :

Année Académique : **2025-2026**

Sommaire

Dédicace iii

Remerciements iv

Résumé v

Abstract vi

List of Figures vii

Liste des figures vii

List of Tables viii

Liste des tableaux viii

Liste des Algorithmes ix

Liste des algorithmes ix

Liste des acronymes x

Glossaire 1

Introduction Générale 2

1 Revue de Littérature 5

2 Analyse, Conception et Choix techniques 18

3 Présentation, évaluation et perspectives 31

Conclusion générale 44

Bibliographie 45

Bibliographie 45

Webographie 46

Table des matières 48

À mes parents,
pour leur amour, leur soutien constant
et les sacrifices consentis tout au long de mon parcours académique.

Remerciements

Je rends grâce à Dieu Tout-Puissant pour la force, la santé et la sagesse qu'Il m'a accordées tout au long de cette formation et qu'il continue toujours de m'accorder.

Mes sincères remerciements vont également à l'ensemble du corps enseignant de l'Institut de Formation et de Recherche en Informatique (IFRI) pour la qualité des enseignements dispensés et l'encadrement académique.

Je tiens à exprimer ma profonde gratitude à mon directeur de mémoire, **M. Armand ACCROMBESSI**, pour sa disponibilité, ses conseils pertinents et son encadrement rigoureux qui ont grandement contribué à la réalisation de ce travail.

Je remercie particulièrement mes parents pour leur soutien moral, financier et affectif, sans lesquels ce parcours n'aurait pu aboutir.

Enfin, j'adresse mes remerciements à tous mes camarades et amis pour l'entraide, les encouragements et les moments de partage.

Résumé

L'orientation universitaire au Bénin constitue un défi majeur pour les nouveaux bacheliers, confrontés à un système complexe recensant 219 filières réparties dans huit institutions publiques, avec un accompagnement personnalisé souvent insuffisant. Le Guide National d'Orientation (GNO) 2024–2025 du Ministère de l'Enseignement Supérieur et de la Recherche Scientifique, bien qu'exhaustif, demeure difficile d'accès et d'interprétation pour une grande partie des candidats. Face à cette problématique, ce mémoire présente la conception et le développement d'un agent conversationnel intelligent dénommé *Mentor Virtuel IA*. Ce système permet de calculer automatiquement la moyenne de classement conformément à la formule officielle, de vérifier l'éligibilité aux allocations d'études et de recommander des filières adaptées au profil académique de chaque étudiant. Afin de garantir des réponses fiables et fondées sur les informations officielles du GNO, la solution proposée s'appuie sur une architecture d'intelligence artificielle générative intégrant la génération augmentée par récupération. Cette approche combine la recherche sémantique d'informations pertinentes et la génération de texte par un modèle de langage, réduisant ainsi les risques d'hallucination et améliorant la précision des réponses fournies. Les résultats obtenus démontrent la pertinence des recommandations générées ainsi que la fiabilité des informations restituées aux utilisateurs. Cette recherche ouvre également des perspectives d'évolution, notamment l'intégration du système aux plateformes de messagerie populaires, la prise en charge des langues locales et un déploiement à grande échelle sur des infrastructures cloud.

Mots clés : intelligence artificielle, orientation universitaire, agent conversationnel, Guide National d'Orientation, Bénin, génération augmentée par récupération, modèle de langage, recommandation de filières.

Abstract

University orientation in Benin represents a major challenge for new high school graduates, who must navigate a complex system comprising 219 academic programs distributed across eight public higher education institutions, often without sufficient personalized guidance. Although comprehensive, the 2024–2025 National Orientation Guide (GNO) published by the Ministry of Higher Education and Scientific Research remains difficult for many candidates to access and interpret. To address this issue, this thesis presents the design and development of an intelligent conversational agent named *Mentor Virtuel IA*. The system automatically computes the admission ranking average according to the official formula, verifies eligibility for study grants, and recommends academic programs that match each student's academic profile. To ensure reliable responses grounded in official GNO information, the proposed solution relies on a generative artificial intelligence architecture based on Retrieval-Augmented Generation (RAG). This approach combines semantic information retrieval with large language model-based text generation, thereby reducing hallucination risks and improving the accuracy and relevance of the responses provided to users. The results demonstrate the effectiveness of the proposed system in delivering relevant recommendations and reliable information. Furthermore, this work opens promising perspectives for future developments, including integration with popular messaging platforms, support for local languages, and large-scale cloud deployment.

Key words: artificial intelligence, university orientation, conversational agent, National Orientation Guide, Benin, Retrieval-Augmented Generation (RAG), large language model, academic program recommendation.

List of Figures

1.1 Agent à base de règles . . . 6
1.2 Agent basé sur l'apprentissage automatique . . . 6
1.3 Les deux types d'agents conversationnels . . . 6
1.4 IAG et LLM . . . 7
1.5 RAG . . . 7
1.6 Modéle de Mistral Embed . . . 9
1.7 Embedding avec similarité sémantique . . . 9
1.8 Le modèle d'embedding de Mistral et celui avec la similarité sémantique . . . 9
1.9 La plateforme Apresbac.bj . . . 11
1.10 La solution Hello Charly . . . 12
1.11 Parcoursup de la France . . . 13
1.12 AdmitHub/ Mainstay aux Etats Unis . . . 14
1.13 Ivy.ai aux Etats Unis . . . 15
1.14 EduBot/ Verge AI . . . 15
1.15 HUTECH et HCMUTE au Vietnam . . . 16

2.1 Diagramme de cas d'utilisation . . . 21
2.2 Diagramme de séquence . . . 22
2.3 Diagramme d'activité du système Mentor Virtuel IA . . . 23
2.4 Mistral AI face aux autres modèles d'IA . . . 24
2.5 Performance des modéles Mistral sur le benchmark Measuring Massive Multitask Language Understanding (MMLU) . . . 24
2.6 Mistral Embed . . . 25
2.7 ChromaDB . . . 25
2.8 La base vectorielle ChromaDB et les autres bases vectorielles . . . 26
2.9 La base de données Supabase . . . 26
2.10 Les technologies du backend . . . 27
2.11 Les technologes du frontend . . . 27

3.1 Page d'accueil du Mentor Virtuel IA . . . 32
3.2 Page d'accueil du Mentor Virtuel IA . . . 32
3.3 Étape 1 — Sélection de la série de baccalauréat . . . 33
3.4 Étape 2 — Saisie des notes et informations personnelles . . . 34
3.5 Étape 3 — Sélection des filières (maximum 3) . . . 34
3.6 Page d'accueil du Mentor Virtuel IA . . . 35
3.7 Étape 4 — Résultats, moyennes et recommandations du Mentor . . . 36
3.8 Étape 4 — Résultats, moyennes et recommandations du Mentor . . . 36

3.9 Étape 4 — Résultats, moyennes et recommandations du Mentor 37
3.10 Page de chat RAG — Interface conversationnelle du Mentor Virtuel 38
3.11 Catalogue des filières — Recherche et filtres multi-critères 39
3.12 Catalogue des filières - Recherche et filtres multi-critères 39

List of Tables

3.1 Résultats des tests API — Postman 40
3.2 Évaluation qualitative de la pertinence RAG 41

Liste des Algorithmes

Liste des Acronymes

API	Application Programming Interface (Interface de Programmation Applicative)
APDP	Autorité de Protection des Données Personnelles
BaaS	Backend as a Service
CRUD	Create, Read, Update, Delete
CSS	Cascading Style Sheets
GNO	Guide National d'Orientation
GPT	Generative Pre-trained Transformer
HTML	HyperText Markup Language
HTTP	HyperText Transfer Protocol
IA	Intelligence Artificielle
JSON	JavaScript Object Notation
LLM	Large Language Model
MESRS	Ministère de l'Enseignement Supérieur et de la Recherche Scientifique
NLP	Natural Language Processing (Traitement Automatique du Langage Naturel)
NLU	Natural Language Understanding (Compréhension du Langage Naturel)
RAG	Retrieval-Augmented Generation (Génération Augmentée par Récupération)
REST	Representational State Transfer
RG	Règle de Gestion
RGPD	Règlement Général sur la Protection des Données
SQL	Structured Query Language
UAC	Université d'Abomey-Calavi
UML	Unified Modeling Language

Glossaire

Agent conversationnel Système informatique capable d'interagir avec un utilisateur en langage naturel afin de répondre à des questions ou d'exécuter certaines tâches.

Base vectorielle Base de données permettant de stocker des représentations numériques appelées embeddings et d'effectuer des recherches par similarité.

Embedding Représentation vectorielle d'un texte permettant de mesurer sa proximité sémantique avec d'autres contenus.

Hallucination (IA) Réponse générée par un modèle d'intelligence artificielle contenant des informations incorrectes ou non vérifiées.

Intelligence artificielle générative Domaine de l'intelligence artificielle permettant de générer du contenu (textes, images, codes, etc.) à partir d'instructions utilisateur.

Large Language Model (LLM) Modèle d'intelligence artificielle entraîné sur de grands volumes de textes capable de comprendre et produire du langage naturel.

Mentor Virtuel IA Assistant conversationnel intelligent développé dans ce mémoire pour aider les bacheliers dans leur orientation universitaire.

Prompt Instruction fournie à un modèle de langage afin de guider sa réponse.

Recherche sémantique Technique permettant de retrouver des informations selon leur sens et non uniquement selon les mots exacts utilisés.

RAG (Retrieval-Augmented Generation) Architecture combinant la recherche documentaire et la génération de texte par un modèle de langage afin de produire des réponses contextualisées.

Token Unité de traitement utilisée par un modèle de langage pour représenter un texte.

Vecteur Représentation numérique d'une donnée dans un espace mathématique de grande dimension.

Introduction Générale

Contexte et justification

La transformation numérique constitue aujourd'hui un levier majeur d'évolution dans plusieurs secteurs, notamment celui de l'éducation. L'intégration des technologies de l'information et de l'intelligence artificielle offre de nouvelles possibilités pour améliorer l'accès à l'information, personnaliser les services et accompagner les utilisateurs dans leurs processus de décision.

Dans le contexte de l'enseignement supérieur en Afrique subsaharienne, la massification des effectifs étudiants et la diversification des offres de formation rendent le choix d'une filière universitaire de plus en plus complexe pour les nouveaux bacheliers. Au Bénin, le Ministère de l'Enseignement Supérieur et de la Recherche Scientifique (MESRS) publie chaque année le Guide National d'Orientation (GNO), un document officiel présentant les différentes filières disponibles dans les universités publiques, leurs conditions d'accès, les critères d'attribution des allocations d'études ainsi que les perspectives associées.

Pour l'année académique 2024–2025, ce guide recense 219 filières réparties dans huit institutions publiques d'enseignement supérieur. Cependant, malgré sa richesse en informations, son volume important, la diversité des critères d'admission et la complexité des règles de calcul rendent son exploitation difficile pour un candidat ne disposant pas d'un accompagnement personnalisé.

Dans ce contexte, l'intelligence artificielle générative apparaît comme une solution prometteuse pour faciliter l'accès à l'information universitaire. Plus particulièrement, les architectures basées sur la génération augmentée par récupération (*Retrieval-Augmented Generation – RAG*) permettent de combiner la capacité conversationnelle des modèles de langage avec une base documentaire fiable, afin de fournir des réponses pertinentes et contextualisées. C'est dans cette perspective que s'inscrit ce travail à travers la conception d'un assistant conversationnel intelligent nommé *Mentor Virtuel IA*, destiné à accompagner les bacheliers béninois dans leur orientation universitaire.

Problématique

L'accès à une orientation universitaire fiable demeure un enjeu important pour les nouveaux bacheliers béninois. Malgré la disponibilité du Guide National d'Orientation, plusieurs difficultés persistent. Premièrement, beaucoup de candidats rencontrent des difficultés à calculer correctement leur moyenne de classement en raison des différentes formules et coefficients appliqués selon les séries du

baccalauréat. Deuxièmement, les critères d'éligibilité aux allocations d'études et aux aides universitaires restent peu connus ou difficiles à interpréter. Enfin, l'absence d'un système d'accompagnement accessible à tout moment limite la capacité des étudiants à obtenir rapidement des réponses adaptées à leur situation.

Par ailleurs, les agents conversationnels basés uniquement sur les grands modèles de langage (*Large Language Models – LLM*) peuvent produire des informations incorrectes ou inventées, ce qui représente une limite importante dans un domaine nécessitant des données officielles et vérifiables.

Dès lors, la question principale de cette étude est la suivante :

Comment concevoir un agent conversationnel intelligent capable d'accompagner efficacement les bacheliers béninois dans leur orientation universitaire, en fournissant des réponses fiables basées sur les données officielles du GNO, tout en automatisant les calculs et les recommandations de filières ?

Ce travail porte principalement sur les filières publiques recensées dans le GNO 2024–2025. Il ne prend pas en compte les établissements privés, les formations de niveau Master et Doctorat, ni les procédures de réorientation des étudiants déjà inscrits.

Objectif général

L'objectif général de ce mémoire est de concevoir et développer un agent conversationnel intelligent basé sur l'intelligence artificielle générative, capable d'assister les nouveaux bacheliers dans leur processus d'orientation universitaire au Bénin à travers l'analyse de leur profil académique, le calcul automatique des critères d'admission et la recommandation de filières adaptées.

Objectifs spécifiques

Pour atteindre cet objectif général, les objectifs spécifiques sont les suivants :

- Collecter, structurer et intégrer les informations du Guide National d'Orientation 2024–2025 afin de construire une base de connaissances fiable et exploitable par le système ;
- Concevoir et mettre en œuvre une architecture intelligente basée sur la recherche sémantique et la génération augmentée par récupération (RAG) afin de fournir des réponses pertinentes et contextualisées ;
- Développer des fonctionnalités d'aide à l'orientation permettant le calcul automatique de la moyenne de classement, la vérification des critères d'éligibilité aux allocations et la recommandation de filières adaptées au profil de chaque bachelier ;
- Implémenter une interface conversationnelle et évaluer les performances du système à travers des tests fonctionnels et des scénarios réels d'utilisation.

Structure du mémoire

Le présent mémoire est structuré en trois chapitres. Dans le premier chapitre, nous présentons le contexte général du projet, la problématique étudiée ainsi qu'une revue de la littérature portant sur les systèmes d'orientation intelligents, les agents conversationnels et les approches basées sur l'intelligence artificielle générative. Ce chapitre expose également les différentes notions nécessaires à la compréhension de l'approche proposée ainsi que les choix méthodologiques retenus. Le deuxième chapitre est consacré à la conception de la solution proposée. Il présente l'analyse des besoins, l'architecture globale du système, les différents composants mis en œuvre ainsi que les choix techniques effectués pour la réalisation de l'agent conversationnel *Mentor Virtuel IA*. Enfin, le troisième chapitre est dédié à l'implémentation de la solution développée. Il décrit les outils et technologies utilisés, la mise en œuvre des différentes fonctionnalités, les tests réalisés ainsi qu'une analyse des résultats obtenus et des perspectives d'amélioration.

Chapitre 1

Revue de Littérature

Introduction

Pour mener à bien ce projet , il est essentiel d'explorer les travaux antérieurs et les solutions existantes dans ce domaine. Ce chapitre pose les fondements théoriques et technologiques du projet *Mentor Virtuel IA*. Il s'articule en quatre sections : une clarification des concepts clés mobilisés, une présentation des solutions existantes, une présentation de l'état de l'art contextualisant les travaux antérieurs réalisés au Bénin entre 2020 et 2026, et de l'étude de quelques plateformes existantes.

1.1 Clarification conceptuelle

1.1.1 Agent conversationnel et chatbot

Un agent conversationnel, communément appelé chatbot, est un programme informatique capable d'interagir avec un utilisateur humain en langage naturel, par écrit ou par la parole. On distingue deux grandes catégories : les agents à base de règles, dont les réponses sont prédéfinies selon des scénarios fixes, et les agents à base d'apprentissage automatique, capables de générer des réponses contextuelles à partir de modèles entraînés sur de larges corpus de textes. Dans le cadre de ce projet, le terme désigne un agent de la seconde catégorie, augmenté d'un mécanisme de récupération documentaire pour garantir la fiabilité de ses réponses.

[t]0.45

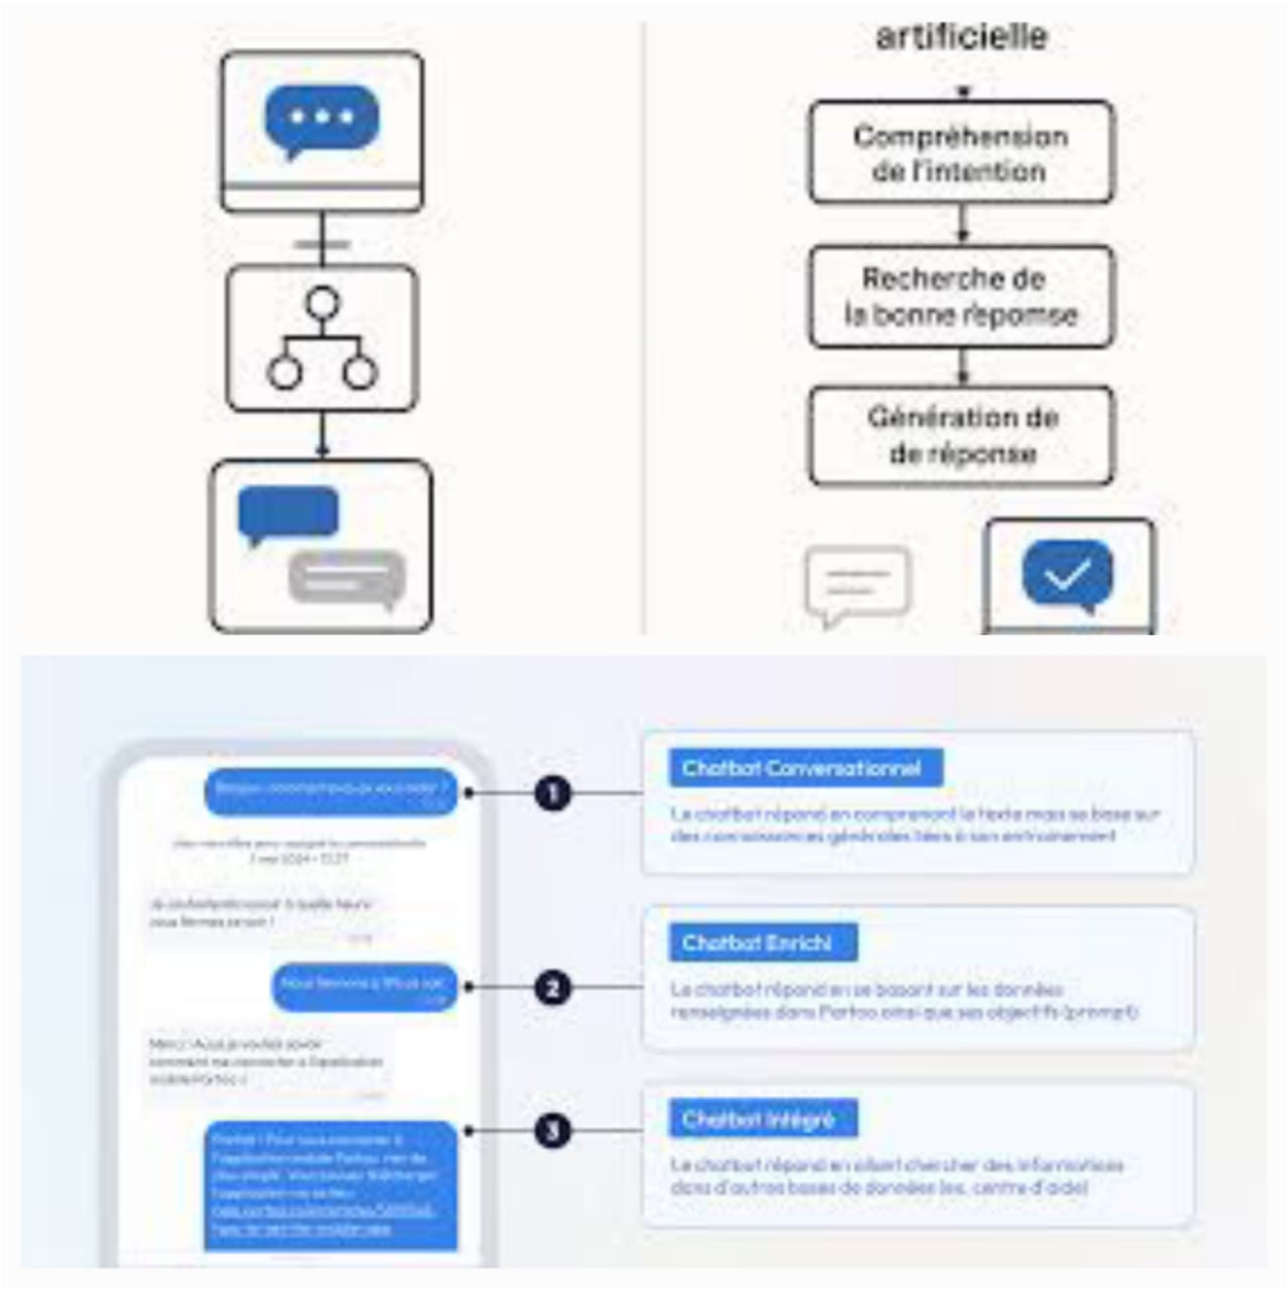
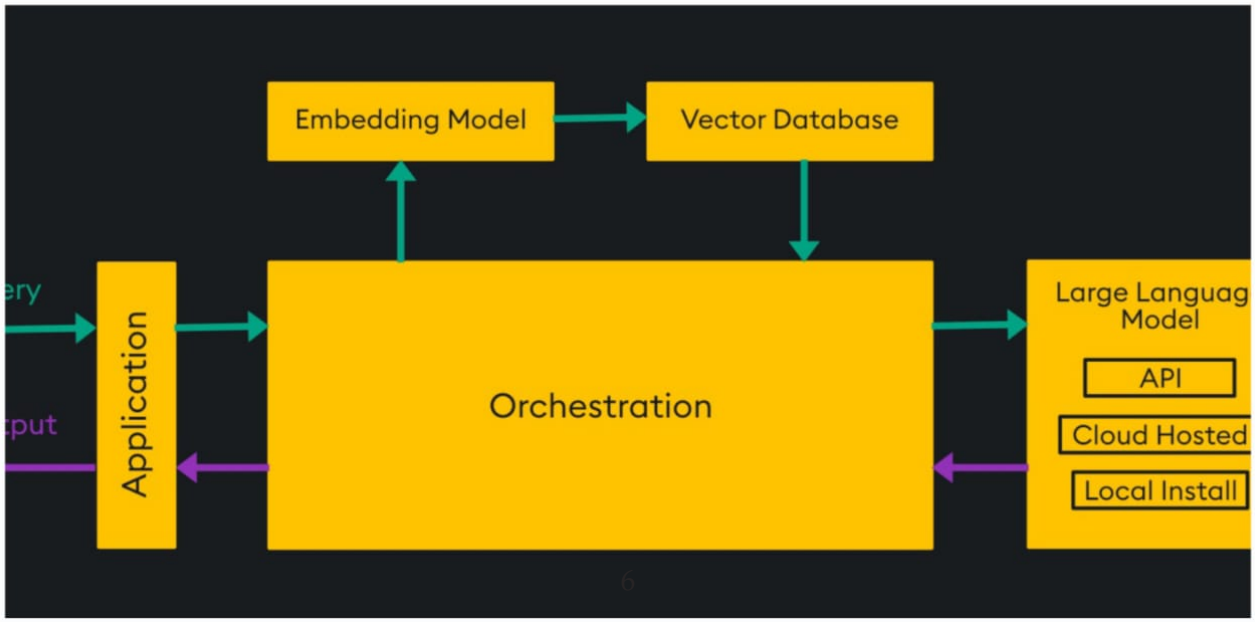


FIGURE 1.1 : Agent à base de règles

[t]0.45



1.1.2 Intelligence artificielle générative et grands modèles de langage

L'intelligence artificielle générative (IAG) désigne la branche de l'IA capable de produire des contenus nouveaux — textes, images, codes — à partir d'un apprentissage sur des données existantes. Les grands modèles de langage (LLM, *Large Language Models*) en constituent le principal vecteur : entraînés sur des milliards de paramètres, ils modélisent les structures du langage naturel et peuvent répondre à des questions complexes, rédiger des synthèses ou conduire un dialogue soutenu. Leur limite principale est le phénomène d'*hallucination* : en l'absence d'ancrage documentaire, le modèle peut générer des affirmations plausibles mais factuellement incorrectes, ce qui est inacceptable dans un contexte d'orientation universitaire où les données (quotas, conditions d'admission, critères de bourses) doivent être exactes.

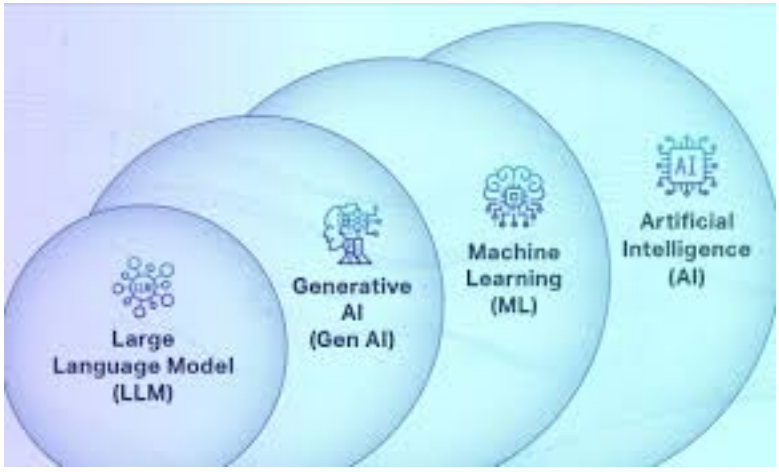


FIGURE 1.4 : IAG et LLM

1.1.3 Architecture RAG (*Retrieval-Augmented Generation*)

L'architecture RAG, introduite par lewis2020retrieval, désigne une approche hybride combinant deux composantes : un module de *récupération* (*retrieval*) qui, à partir d'une requête, extrait les passages les plus pertinents d'une base documentaire, et un module de *génération* qui utilise ces passages comme contexte pour produire une réponse fondée. Formellement, pour une question q, le système récupère un ensemble de documents $\mathcal{D}_q = \{d_1, d_2, \ldots, d_k\}$ maximisant un score de similarité, puis génère une réponse $r = \text{LLM}(q, \mathcal{D}_q)$. Cette architecture garantit que les réponses restent *ancrées* dans un corpus contrôlé et vérifiable, éliminant ainsi le risque d'hallucination. Dans le présent projet, le corpus est constitué des 219 filières du Guide National d'Orientation 2024-2025.

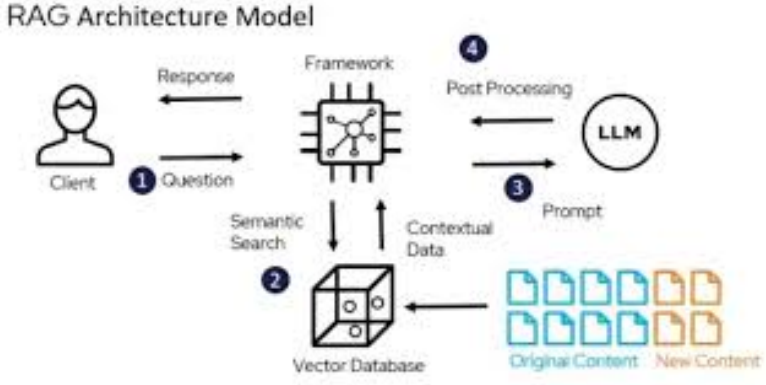


FIGURE 1.5 : RAG

1.1.4 Embedding et similarité sémantique

Un embedding est une représentation vectorielle dense d'un texte dans un espace de grande dimension, telle que deux textes sémantiquement proches se trouvent à faible distance l'un de l'autre dans cet espace. La similarité cosinus, définie par $\cos(\theta) = \frac{\vec{u} \cdot \vec{v}}{\|\vec{u}\|\|\vec{v}\|}$, est la mesure standard utilisée pour comparer ces vecteurs : une valeur proche de 1 indique une forte similarité sémantique. Dans le système développé, chaque filière est transformée en vecteur par le modèle *mistral-embed*, et la recherche d'une filière pertinente revient à trouver le vecteur le plus proche de la requête de l'étudiant.

[t]0.45

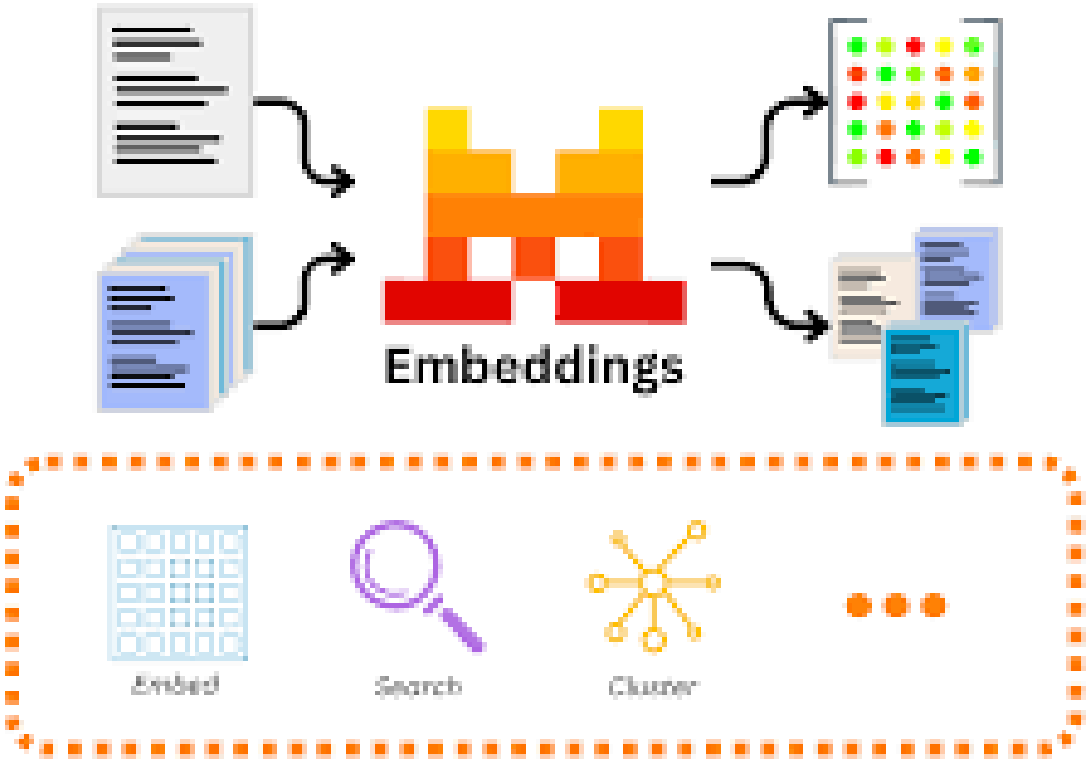


FIGURE 1.6 : Modéle de Mistral Embed

[t]0.45

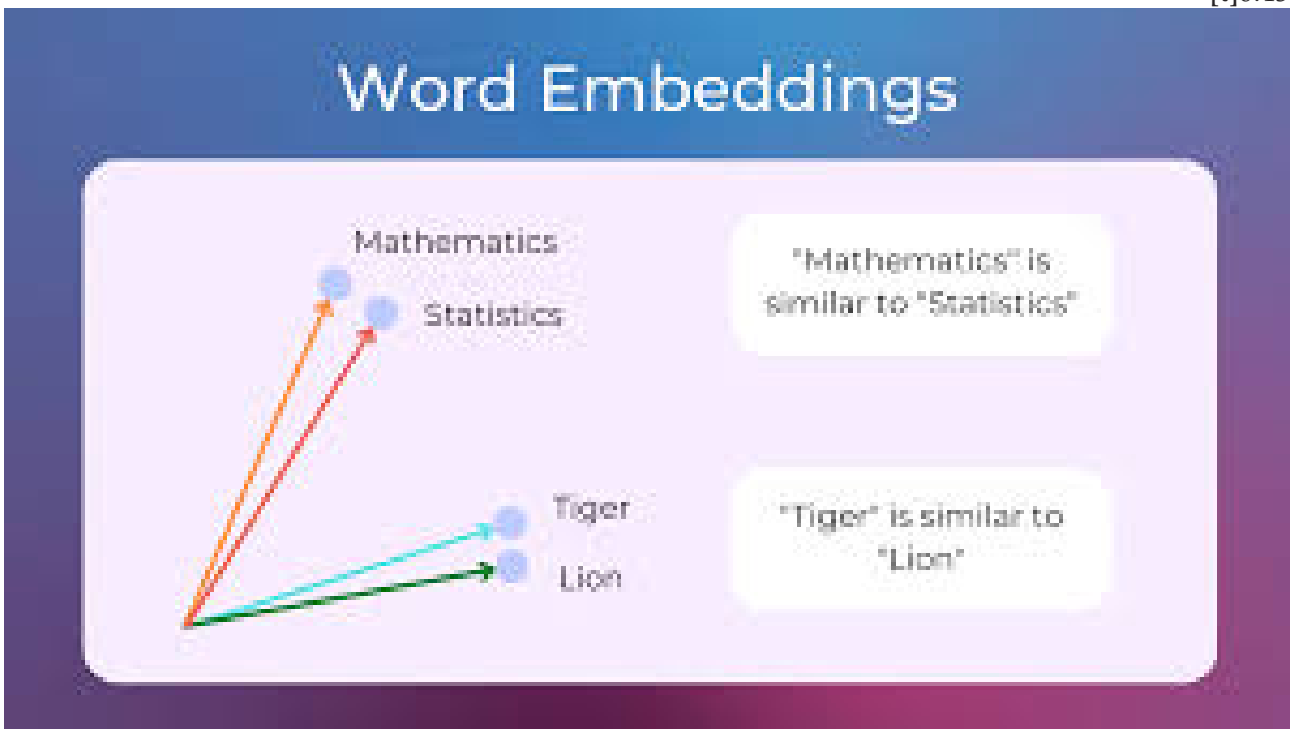


FIGURE 1.7 : Embedding avec similarité sémantique

FIGURE 1.8 : Le modèle d'embedding de Mistral et celui avec la similarité sémantique

1.1.5 Orientation universitaire et système d'allocation au Bénin

L'orientation universitaire désigne l'ensemble des processus d'information, de conseil et d'aide à la décision permettant à un bachelier d'identifier et de choisir une formation adaptée à son profil académique et à ses aspirations professionnelles. Au Bénin, ce processus est encadré par le MESRS à travers le GNO, qui définit pour chaque filière publique : le mode d'entrée (classement ou concours), les séries de baccalauréat recommandées, les matières fondamentales et leurs coefficients, et les quotas de bourses nationales et d'aides universitaires. L'éligibilité à ces allocations est régie par des règles précises : âge maximum de 21 ans pour la bourse, de 26 ans pour le secours, bonification de 2 ans pour les personnes en situation de handicap et de nationalité béninoise obligatoire.

1.2 Solutions et approches existantes

L'analyse des solutions disponibles à l'échelle internationale et nationale permet d'identifier les approches déjà explorées et de positionner clairement la contribution de ce projet.

1.2.1 Systèmes de recommandation académique basés sur les données

À l'échelle internationale, plusieurs plateformes exploitent des algorithmes de recommandation pour guider les étudiants dans leur choix d'orientation. Parimi et al. (2021) proposent un système basé sur la filtration collaborative appliqué aux choix de filières en Inde, tandis que le projet EduBot de Zhang et al. (2022) utilise un modèle BERT fine-tuné pour répondre aux questions d'admission dans les universités chinoises. Ces approches partagent une limite commune : elles reposent sur des données historiques d'admission (résultats des années précédentes) qui ne sont pas systématiquement disponibles ou structurées dans le contexte béninois.

1.2.2 Chatbots institutionnels dans l'enseignement supérieur africain

En Afrique, des initiatives comme le chatbot UNISA (Afrique du Sud, 2021) pour le support aux étudiants à distance, ou le système KAGUYA de l'Université de Dakar (2023) pour la gestion des inscriptions, montrent la faisabilité technique des agents conversationnels dans des contextes à faible infrastructure. Ces systèmes restent cependant limités à des fonctions administratives réactives et ne proposent pas d'analyse personnalisée du profil académique.

1.2.3 Approches RAG dans l'éducation

L'application de l'architecture RAG au domaine éducatif est encore émergente. Gao et al. (2023) démontrent dans leur revue systématique que les systèmes RAG surpassent les LLM seuls de 15 à 40 % sur les tâches de questions-réponses nécessitant des faits précis et vérifiables, exactement le type de tâche requis pour l'orientation universitaire. Parmi les rares implémentations documentées dans des contextes éducatifs africains, aucune ne porte spécifiquement sur l'orientation post-bac avec ancrage sur un guide officiel national.

1.2.4 Positionnement du Mentor Virtuel IA

Par rapport aux solutions existantes, le *Mentor Virtuel IA* se distingue sur trois points : la souveraineté documentaire (le corpus est exclusivement le GNO officiel du MESRS, actualisable annuelle-

ment), l'intégration des règles de gestion réglementaires (calcul de moyenne, éligibilité aux bourses) dans le flux conversationnel, et l'accessibilité web. Il constitue à ce jour la première solution RAG documentée appliquée à l'orientation universitaire publique au Bénin.

1.3 État de l'art : systèmes conversationnels et écosystème de l'orientation universitaire au Bénin (2020–2026)

1.3.1 Dématérialisation administrative et support citoyen

Les travaux du MESRS en 2020 ont abouti au déploiement du portail *apresmonbac.bj*, première infrastructure nationale de centralisation des vœux, introduisant un agent conversationnel de premier niveau essentiellement réactif. Frèd AKOCO et Oswald AKLOVIS ont quant à eux modélisé un chatbot dédié à la gestion des inscriptions et des renseignements sur les frais de scolarité dans un cadre universitaire privé en 2024. Si ces deux solutions réussissent la dématérialisation des procédures administratives, elles restent cantonnées à une fonction utilitaire : l'usager y est considéré comme un dossier à traiter, sans analyse de ses aspirations ni réponse à la question fondamentale du *pourquoi choisir cette filière*.

1.3.2 Algorithmique de recommandation et aide à la décision

L'équipe SADELINS a déployé la plateforme *apresbac.bj* en 2025,analysant plus de 50 paramètres pour fournir des probabilités d'admission précises. Les travaux de Frédéric NGABA sur le système OSIA (*Objectif Stratégie Indicateurs et Actions*) ont influencé les pratiques locales par son concept de *verdict d'orientation prévisionnelle*. Ces deux approches convergent sur le diagnostic de l'asymétrie d'information comme premier frein à une bonne orientation, mais l'interaction reste dominée par des formulaires statiques et dans certains cas, monétisée, créant une fracture entre les bacheliers qui peuvent se payer un conseil de qualité et les autres.



FIGURE 1.9 : La plateforme Apresbac.bj

1.3.3 IA générative et médiation humain-machine

Le modèle *GPT-BJ*, développé par Marc-André LOKO (ASIN) en 2023 constitue le premier socle d'IA générative souveraine au Bénin, facilitant l'accès aux réglementations nationales par le dialogue

naturel. Les recherches du Dr Jonas FASSINOU en 2025 sur l'IAG au secondaire ont établi que l'IA n'a pas vocation à remplacer le conseiller d'orientation, mais à agir comme un « amplificateur de portée ». Ces travaux soulèvent néanmoins un risque majeur : sans base de données fermée et certifiée (RAG), ces IA peuvent suggérer des filières inexistantes ou des quotas obsolètes, compromettant le projet de l'étudiant.

1.3.4 Inclusion linguistique et souveraineté numérique

Le projet *JaimeMaLangue* (LALEYE Fréjus A. A. et al., 2025) constitue une initiative majeure de collecte de voix pour permettre à l'IA de comprendre et de parler le Fon, le Yoruba et le Bariba. Les travaux d'Ahia OREVAOGHENE et al. en 2024, au sein de la communauté Masakhane, ont adressé les défis techniques de la tonalité et des diacritiques dans les dialectes Yoruba. Ces travaux s'accordent sur le fait que l'IA doit être « ancrée dans la culture » pour constituer un véritable levier d'équité sociale. Il n'existe cependant pas encore d'application d'orientation fonctionnelle « bout en bout » utilisant ces technologies vocales locales.

1.3.5 Psychopédagogie et mentorat de carrière

E. Béatrice KOUMENOUGBO, en 2020 a démontré à l'UAC que la majorité des inscriptions en facultés classiques se font par défaut, faute d'un accompagnement psychologique adéquat, établissant un lien direct entre le stress post-bac et le taux d'échec en première année. L'application *Hello Charly* (A. SANOGO et al., 2025) propose une solution de mentorat conversationnel visant à rendre le jeune acteur de son projet professionnel. Ces travaux convergent sur le diagnostic mais divergent sur la solution : KOUMENOUGBO prône une restructuration administrative, SANOGO une technologie de compagnonnage continu. Les solutions de type *Hello Charly* restent souvent déconnectées des réalités béninoises (critères de bourses nationaux, métiers prioritaires du PAG 2021-2026).



FIGURE 1.10 : La solution Hello Charly

1.3.6 Synthèse et lacunes identifiées

L'examen des travaux réalisés entre 2020 et 2026 révèle un écosystème en mutation mais structurellement fragmenté. Trois lacunes majeures persistent : la *froideur transactionnelle* des systèmes actuels qui ignorent la dimension émotionnelle du processus décisionnel ; le *risque d'hallucination* des IA génératives non ancrées dans les données certifiées du MESRS ; et *l'exclusion économique* liée à la monétisation des solutions les plus avancées. Le *Mentor Virtuel IA* répond directement à ces trois lacunes en proposant un *Compagnonnage Numérique Souverain et Holistique* : un agent ancré dans le GNO officiel, intégrant les règles réglementaires de calcul et d'éligibilité, et proposant nativement des alternatives EFTP en cas de non-admission dans les filières sélectives.

1.4 Étude de quelques plateformes existantes

Afin de positionner notre solution par rapport aux approches existantes, nous avons étudié cinq plateformes ou systèmes représentatifs dans le domaine de l'orientation universitaire assistée par intelligence artificielle. Cette analyse met en évidence leurs principales fonctionnalités, leurs architectures techniques ainsi que leurs limites face aux besoins d'un système d'orientation intelligent adapté à un contexte universitaire spécifique.

1.4.1 Parcoursup (France)



FIGURE 1.11 : Parcoursup de la France

Parcoursup est la plateforme nationale française de préinscription dans l'enseignement supérieur, permettant à environ 900 000 candidats chaque année de consulter les formations disponibles et de formuler leurs vœux d'orientation. Son fonctionnement est complété par des outils d'intelligence artificielle tiers tels que ChatGPT, Kursus AI ou Thotis, capables d'aider les étudiants à explorer les filières, comparer les établissements, identifier des débouchés professionnels et construire une stratégie de candidature. L'infrastructure principale repose sur un système centralisé administré par le Ministère de l'Enseignement Supérieur français, tandis que les assistants IA associés utilisent principalement des modèles de langage de type GPT et des moteurs de recommandation basés sur les profils scolaires. Toutefois, ces outils restent limités car ils n'ont pas accès aux mécanismes internes de sélection de Parcoursup, ne permettent pas d'estimer précisément les chances d'admission et ne prennent pas toujours en compte les spécificités locales ou les critères propres aux établissements.

1.4.2 AdmitHub / Mainstay (États-Unis)



FIGURE 1.12 : AdmitHub/ Mainstay aux Etats Unis

AdmitHub, aujourd'hui connu sous le nom de Mainstay, est un chatbot intelligent destiné à accompagner les étudiants durant le processus d'admission universitaire. La plateforme fournit une assistance personnalisée pour la constitution des dossiers, l'envoi de rappels, le suivi des candidatures et la communication entre étudiants et établissements. Techniquement, elle repose sur une architecture conversationnelle combinant intelligence artificielle et traitement automatique du langage naturel, entraînée sur des bases de connaissances propres aux établissements partenaires et intégrée aux systèmes d'information universitaires via différents canaux comme le SMS ou les interfaces web. Malgré son efficacité dans l'accompagnement administratif, AdmitHub ne propose pas de moteur avancé de recommandation de parcours académique, ne calcule pas de score de classement et son utilisation reste fortement dépendante d'un partenariat institutionnel, ce qui limite son adoption dans les environnements disposant de moins de ressources.

1.4.3 Ivy.ai (États-Unis)



FIGURE 1.13 : Ivy.ai aux Etats Unis

Ivy.ai est une plateforme de chatbot basée sur l'intelligence artificielle destinée aux établissements d'enseignement supérieur. Elle offre des services variés couvrant les admissions, l'aide financière, l'accompagnement académique et l'orientation professionnelle grâce à un assistant disponible en continu. Son architecture repose sur un chatbot entraîné à partir des contenus institutionnels des universités, utilisant des techniques de traitement automatique du langage naturel afin d'identifier les demandes des étudiants et fournir des réponses adaptées. La solution peut également être connectée aux systèmes d'information étudiants et aux plateformes pédagogiques existantes. Cependant, Ivy.ai reste principalement un outil conversationnel généraliste : il ne possède pas de mécanisme spécialisé de recommandation de filières selon les performances académiques, ne réalise pas de calcul réglementaire de scores et peut produire des réponses imprécises lorsque les informations institutionnelles utilisées ne sont pas régulièrement mises à jour.

1.4.4 EduBot / Verge AI (International)

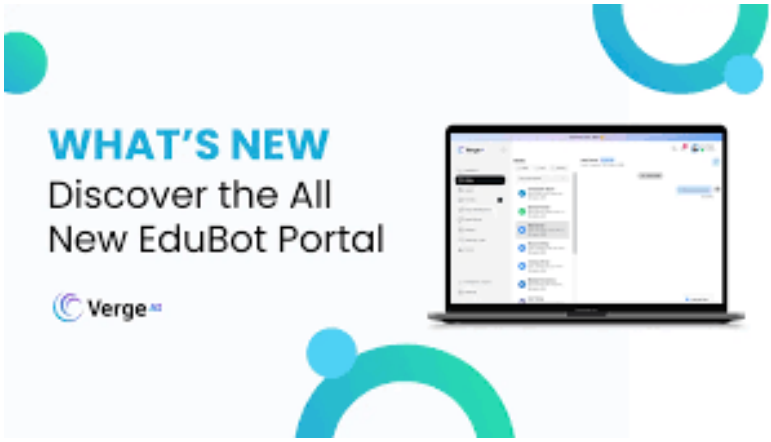


FIGURE 1.14 : EduBot/ Verge AI

EduBot, développé par Verge AI, est une plateforme d'assistance intelligente destinée aux établissements universitaires. Elle accompagne les étudiants dans les démarches d'admission, l'inscription aux cours, le conseil pédagogique et le choix des parcours académiques, avec une prise en charge multilingue. La solution s'appuie sur une architecture basée sur Microsoft Azure et des modèles de

langage avancés comme GPT-4, capables d'exploiter des documents institutionnels tels que des fichiers PDF, des bases de questions fréquentes ou des contenus pédagogiques afin de générer des réponses contextualisées. Malgré son niveau d'intégration élevé, EduBot ne propose pas de système complet d'orientation basé sur les résultats scolaires, ne réalise pas de calcul automatique d'éligibilité ou de classement, et son exploitation nécessite une infrastructure technique importante pouvant représenter un coût élevé pour certaines universités.

1.4.5 Chatbots universitaires vietnamiens — HUTECH et HCMUTE



FIGURE 1.15 : HUTECH et HCMUTE au Vietnam

Les universités vietnamiennes HUTECH et HCMUTE ont développé des chatbots intelligents pour accompagner les candidats lors des périodes d'admission universitaire. Ces systèmes permettent aux étudiants d'obtenir des informations sur les formations disponibles, les modalités d'inscription, les politiques de bourses et les perspectives professionnelles associées aux différentes spécialisations. Leur architecture repose sur des agents conversationnels alimentés par des bases documentaires institutionnelles régulièrement mises à jour, permettant une interaction naturelle avec les candidats sans nécessiter une authentification préalable. Cependant, ces solutions restent principalement orientées vers l'information et l'assistance, sans intégrer un véritable moteur de décision capable de calculer automatiquement un score académique, de vérifier les conditions d'accès aux formations ou de proposer une orientation personnalisée basée sur les résultats réels des étudiants.

Conclusion

Ce chapitre a permis de présenter les concepts fondamentaux relatifs à l'intelligence artificielle, aux agents conversationnels, aux grands modèles de langage et à l'architecture RAG. L'étude des solutions existantes a mis en évidence l'intérêt de ces technologies pour l'accompagnement à l'orientation universitaire. Cependant, l'analyse comparative a révélé certaines limites, notamment l'absence d'une solution intégrant à la fois la recommandation de filières, le calcul du score de classement et la vérification de l'éligibilité aux allocations. Cette situation justifie le développement du Mentor Virtuel IA, fondé sur les données officielles du Guide National d'Orientation. Les résultats de cette étude ont permis de définir les principaux besoins fonctionnels et techniques du projet. Ils constituent ainsi une base solide pour la conception de la solution présentée dans le chapitre suivant.

Chapitre 2

Analyse, Conception et Choix techniques

Introduction

Ce chapitre présente l'analyse des besoins et des contraintes, la conception de la solution ainsi que les choix techniques retenus pour le développement de *Mentor Virtuel IA*. Il expose les besoins fonctionnels et non fonctionnels du système, l'architecture générale de la solution et les technologies utilisées pour sa mise en œuvre.

2.1 Analyse des besoins et des contraintes

2.1.1 Besoins fonctionnels

Les besoins fonctionnels décrivent les services que le système doit fournir aux utilisateurs afin de répondre aux objectifs du projet. Dans le cadre du développement de *Mentor Virtuel IA*, le système doit permettre :

- de collecter et exploiter les données du GNO ;
- d'interagir avec les utilisateurs à travers une interface conversationnelle en langage naturel ;
- de calculer automatiquement la moyenne de classement des bacheliers conformément aux règles officielles du MESRS ;
- de vérifier l'éligibilité des candidats aux allocations d'études selon les critères définis dans le GNO ;
- de recommander des filières adaptées au profil académique et aux préférences de l'utilisateur ;
- de rechercher et restituer des informations pertinentes à partir de la base documentaire du GNO ;
- de conserver l'historique des conversations afin d'améliorer l'expérience utilisateur ;
- de permettre à un administrateur de mettre à jour les données du système lorsque de nouvelles éditions du GNO sont publiées. "'

2.1.2 Besoins non fonctionnels

Les besoins non fonctionnels représentent les contraintes de qualité auxquelles le système doit satisfaire afin d'assurer son bon fonctionnement. Ils concernent notamment la performance, la sécurité, la disponibilité et l'utilisabilité du système.

Le système doit ainsi garantir :

- une disponibilité permanente du service pour les utilisateurs ;
- un temps de réponse réduit lors des interactions conversationnelles ;
- la fiabilité des informations fournies grâce à l'utilisation exclusive des données officielles du GNO ;
- la sécurité et la confidentialité des données personnelles des utilisateurs conformément aux exigences de l'APDP ;
- une interface ergonomique, intuitive et accessible sur ordinateur et smartphone ;
- une architecture évolutive permettant l'intégration future de nouvelles fonctionnalités et de nouvelles sources de données ;
- la maintenabilité du code afin de faciliter les mises à jour et les évolutions du système. "'

2.1.3 Critères d'évaluation

Afin de mesurer l'efficacité de la solution proposée, plusieurs critères d'évaluation sont retenus :

- la pertinence des recommandations de filières proposées aux utilisateurs ;
- l'exactitude des calculs de moyenne de classement réalisés par le système ;
- la précision des réponses générées à partir des données du GNO ;
- le temps moyen de réponse de l'assistant conversationnel ;
- le taux de satisfaction des utilisateurs ;
- le taux de réussite des scénarios de tests fonctionnels ;
- la capacité du système à réduire les hallucinations grâce à l'approche RAG. "'

2.1.4 Contraintes techniques

La réalisation de *Mentor Virtuel IA* est soumise à plusieurs contraintes techniques :

- les informations du GNO sont principalement disponibles sous forme de documents PDF nécessitant un traitement préalable pour leur intégration dans la base documentaire ;
- les performances du système dépendent des temps de réponse des services d'intelligence artificielle utilisés ;
- la précision des recommandations repose sur la qualité des données extraites du GNO ;

- les ressources matérielles disponibles doivent permettre le stockage et l'indexation des données vectorielles utilisées par l'approche RAG ;
- le système doit être compatible avec les navigateurs web modernes et les appareils mobiles ;
- les exigences réglementaires relatives à la protection des données personnelles doivent être respectées tout au long du cycle de vie du système. "'

2.2 Conception du système

2.2.1 Architecture générale

Le système *Mentor Virtuel IA* repose sur une architecture multicouche composée d'une interface utilisateur, d'un serveur applicatif et d'une couche de données. L'interface web permet aux utilisateurs d'interagir avec la plateforme à travers un parcours d'orientation et un assistant conversationnel. Le serveur applicatif centralise la logique métier, le traitement des requêtes et la communication avec les services externes. La couche de données combine une base relationnelle pour le stockage des informations structurées et une base vectorielle dédiée à la recherche sémantique. L'intelligence du système repose sur une architecture de type RAG, qui associe un mécanisme de recherche documentaire à un modèle de langage afin de fournir des réponses fiables, contextualisées et fondées sur les informations officielles du GNO.

2.2.2 Diagramme des cas d'utilisation

Le diagramme de cas d'utilisation permet de représenter les interactions entre les différents acteurs du système et les fonctionnalités offertes par la plateforme *Mentor Virtuel IA*. Il met en évidence les services accessibles aux utilisateurs ainsi que les échanges avec les organismes externes impliqués dans le processus d'orientation.

Trois acteurs principaux interviennent dans le système :

- le **Bachelier**, acteur principal, qui utilise la plateforme pour consulter ses informations académiques, obtenir des recommandations de filières et interagir avec l'assistant conversationnel ;
- le **MESRS** (Ministère de l'Enseignement Supérieur et de la Recherche Scientifique), qui fournit les données officielles relatives aux filières universitaires et aux conditions d'admission ;
- l'**APDP** (Autorité de Protection des Données Personnelles), qui intervient dans le cadre de la protection des données personnelles et du recueil du consentement des utilisateurs.

Les principales fonctionnalités offertes par le système sont l'authentification de l'utilisateur, la consultation des données académiques, le calcul de la moyenne de classement selon la formule $M = \frac{m_1x+m_2y+m_3z}{x+y+z}$, la vérification de l'admissibilité aux filières, la consultation des filières disponibles, la sélection des choix d'orientation ainsi que la réception de recommandations personnalisées. Le système peut également suggérer des alternatives adaptées lorsque les choix formulés ne correspondent pas au profil académique du candidat.

La figure 2.2 présente le diagramme de cas d'utilisation du système *Mentor Virtuel IA*.

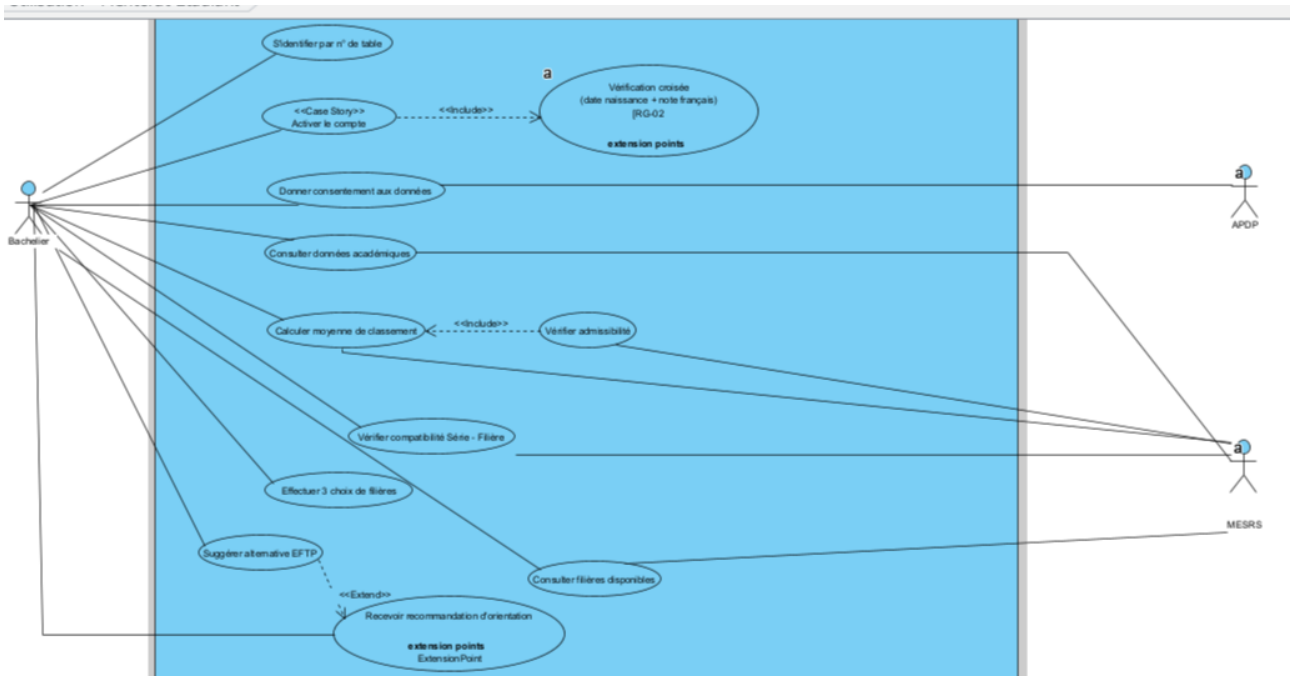


FIGURE 2.1 : Diagramme de cas d'utilisation

2.2.3 Diagramme de séquence

Le diagramme de séquence représente le déroulement chronologique des échanges entre les différents acteurs et composants du système lors d'une session d'orientation universitaire. Il met en évidence les interactions nécessaires à la collecte des informations de l'utilisateur, au traitement de sa demande et à la production des recommandations.

Le diagramme fait intervenir cinq participants principaux : le **Bachelier**, qui initie les différentes actions ; le **Mentor Virtuel IA**, qui assure le traitement des requêtes et la coordination des opérations ; la **Base de Données Nationale**, qui stocke les informations académiques et les données nécessaires au fonctionnement du système ; le **Service d'Allocation**, utilisé pour la vérification des informations liées aux aides universitaires ; et le **Guide National d'Orientation (MESRS)**, qui constitue la source officielle des données relatives aux filières et aux conditions d'accès.

Le processus débute par l'identification du bachelier et la vérification des informations nécessaires à son authentification. L'utilisateur procède ensuite à la sélection des filières qui l'intéressent. Le système analyse alors son profil académique, consulte les données disponibles et effectue les traitements requis afin d'évaluer les possibilités d'admission. Il vérifie également les informations nécessaires à l'attribution des allocations d'études avant de générer des recommandations adaptées au profil de l'utilisateur.

Le diagramme met ainsi en évidence la coordination entre les différents services du système pour fournir une assistance personnalisée et faciliter le processus d'orientation universitaire.

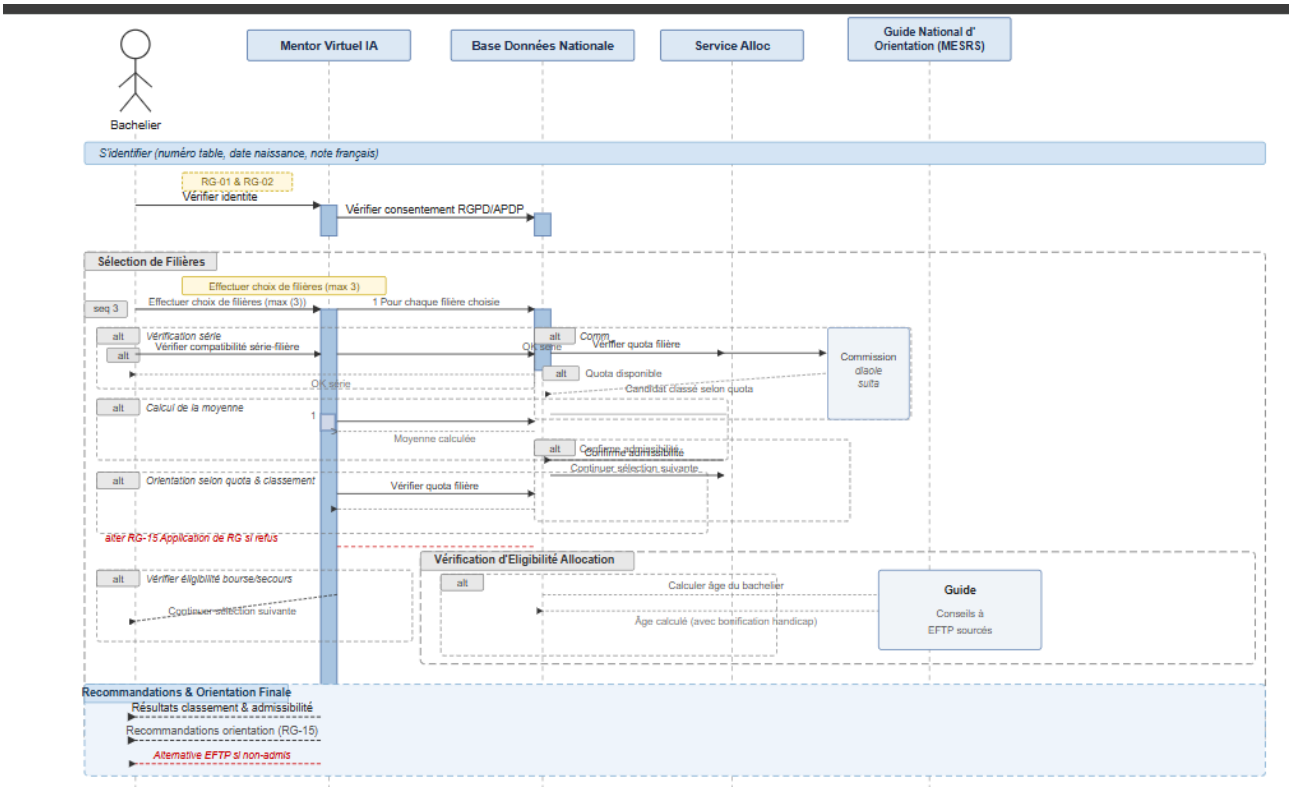


FIGURE 2.2 : Diagramme de séquence

2.2.4 Diagramme d'activités

Le diagramme d'activité représente le déroulement global du processus d'orientation universitaire au sein de la plateforme *Mentor Virtuel IA*. Il met en évidence les différentes activités réalisées par les acteurs du système ainsi que les échanges entre les composants intervenant dans la production des recommandations personnalisées.

Le processus débute par l'authentification du bachelier et le recueil de son consentement pour l'utilisation de ses données personnelles. Une fois cette étape validée, le système vérifie les informations fournies et récupère les données académiques nécessaires à l'analyse du profil de l'utilisateur.

Le *Mentor Virtuel IA* effectue ensuite plusieurs traitements, notamment le calcul de la moyenne de classement, la vérification de l'éligibilité aux allocations d'études et l'analyse du profil académique du candidat. Ces informations permettent d'identifier les filières les plus adaptées à son parcours et à ses résultats.

Afin de produire des recommandations fiables, le système interroge la base documentaire issue du GNO pour rechercher les informations pertinentes. Les données récupérées sont ensuite traitées par le moteur RAG, qui réalise une recherche sémantique avant de générer une réponse contextualisée à partir des documents officiels.

À partir de ces résultats, le système élabore des recommandations personnalisées. Lorsque les informations obtenues sont jugées suffisamment pertinentes, les recommandations sont préparées et présentées à l'utilisateur. Dans le cas contraire, des alternatives d'orientation sont proposées afin d'offrir d'autres possibilités compatibles avec son profil académique.

Enfin, le bachelier consulte les recommandations fournies, peut poser des questions complémentaires à l'assistant conversationnel et reçoit des réponses adaptées à ses besoins. Le processus se termine lorsque l'utilisateur valide son choix d'orientation.

La figure 2.3 présente le diagramme d'activité du processus d'orientation universitaire mis en œuvre par *Mentor Virtuel IA*.

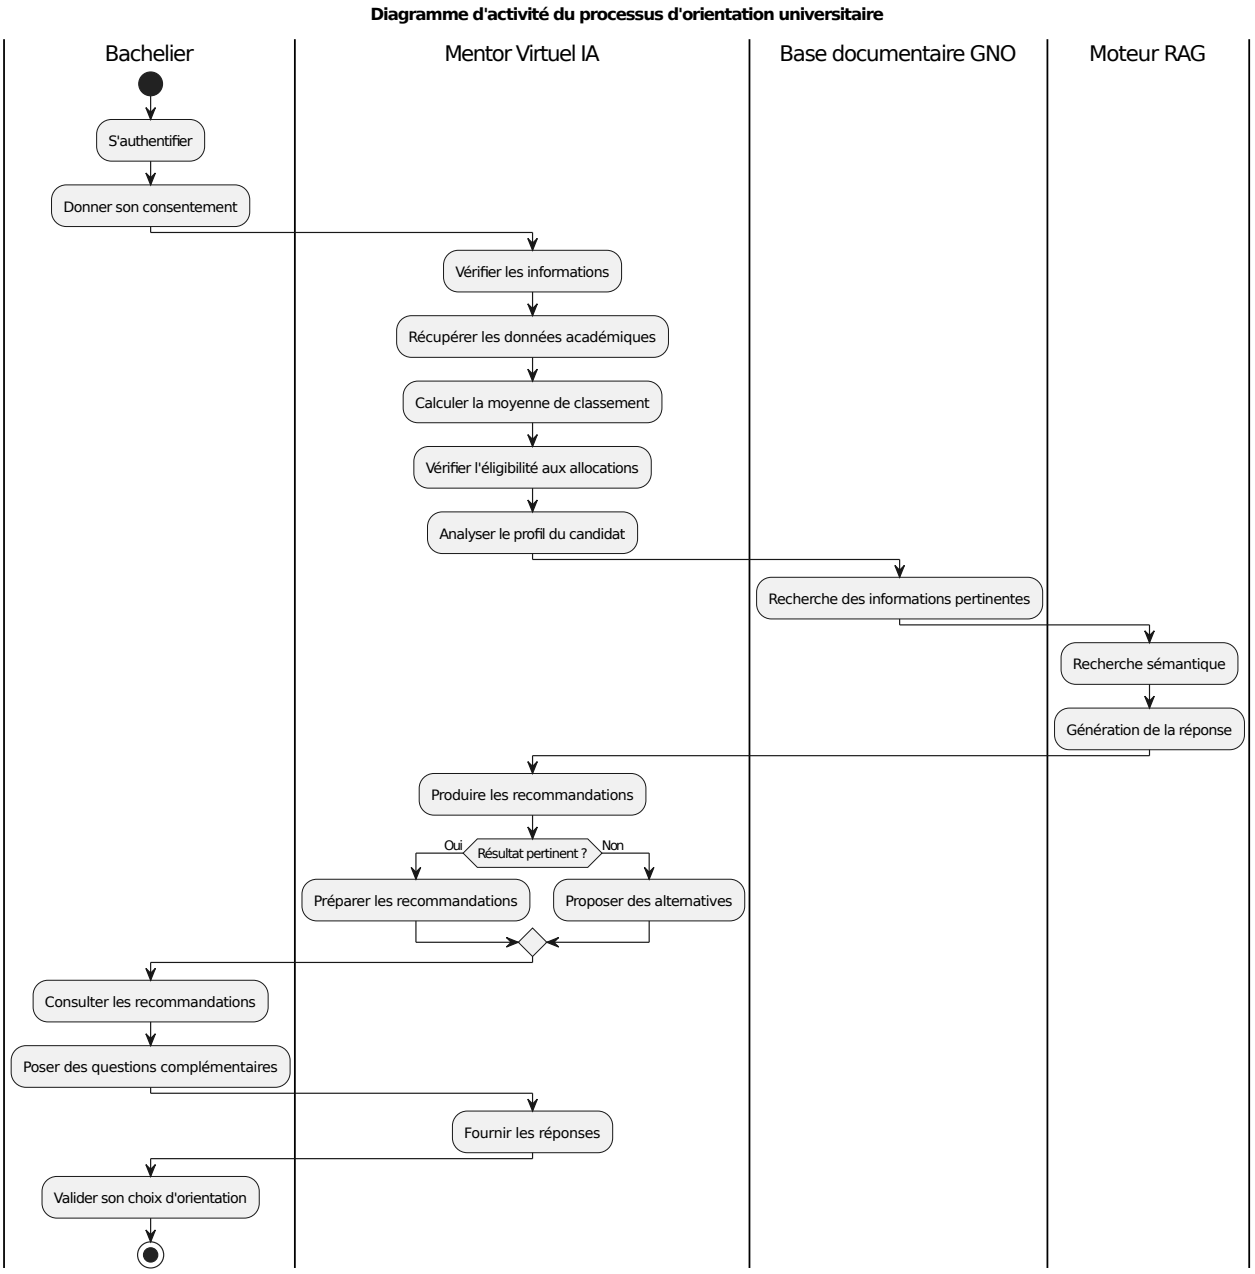


FIGURE 2.3 : Diagramme d'activité du système Mentor Virtuel IA

2.2.5 Architecture conversationnelle

2.3 Choix techniques

2.3.1 Justification des technologies utilisés

Le choix des technologies repose sur une analyse comparative prenant en compte l'adéquation aux besoins du projet,la sécurité des données, la facilité de déploiement, la maturité des outils et leur coût.

2.3.1.1 Mistral AI — modèle de langage et d'embedding

Mistral AI est une entreprise française fondée en 2023, il a été choisi pour sa souveraineté, ses performances en français et son accessibilité pour un projet académique.

le **mistral-large-latest** est le modèle de génération retenu pour produire les réponses du Mentor Virtuel. Sa fenêtre de contexte de 128 000 tokens permet d'intégrer simultanément le prompt système, l'historique de la conversation et les documents RAG récupérés, sans troncature.

le **mistral-embed** est le modèle d'embedding utilisé pour transformer les descriptions textuelles des filières en vecteurs de dimension 1 024. Ce model permet de transformer les descriptions des filières en vecteurs numériques afin de réaliser la recherche sémantique.

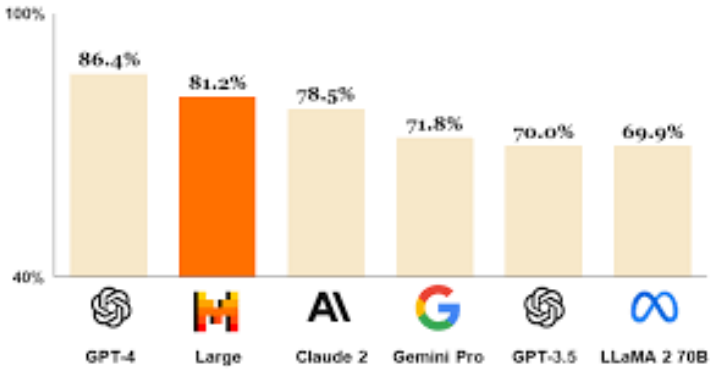


FIGURE 2.4 : Mistral AI face aux autres modèles d'IA

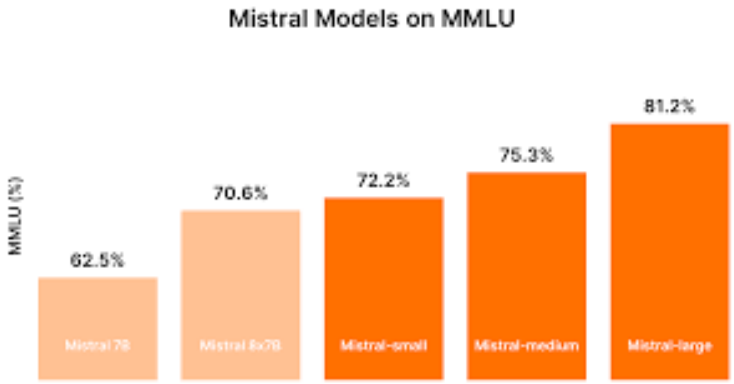


FIGURE 2.5 : Performance des modéles Mistral sur le benchmark Measuring Massive Multitask Language Understanding (MMLU)

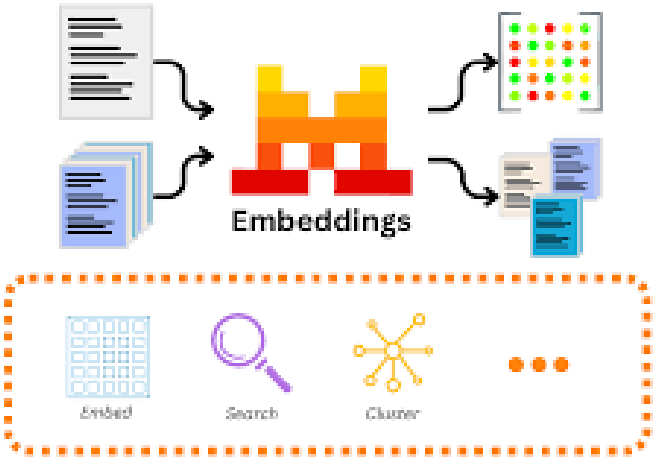


FIGURE 2.6 : Mistral Embed

2.3.1.2 ChromaDB — base de données vectorielle

ChromaDB a été retenue pour stocker et rechercher rapidement les embeddings générés par Mistral AI. Son caractère open-source, son déploiement local et sa simplicité d'utilisation en font une solution adaptée à une architecture RAG. Elle permet d'associer chaque filière à ses informations descriptives afin de retrouver les contenus les plus pertinents lors des échanges avec le chatbot.Par rapport à des alternatives comme Pinecone (payant) ou Weaviate (plus complexe à configurer), ChromaDB présente le meilleur rapport fonctionnalité/simplicité pour un projet de type RAG académique.



FIGURE 2.7 : ChromaDB

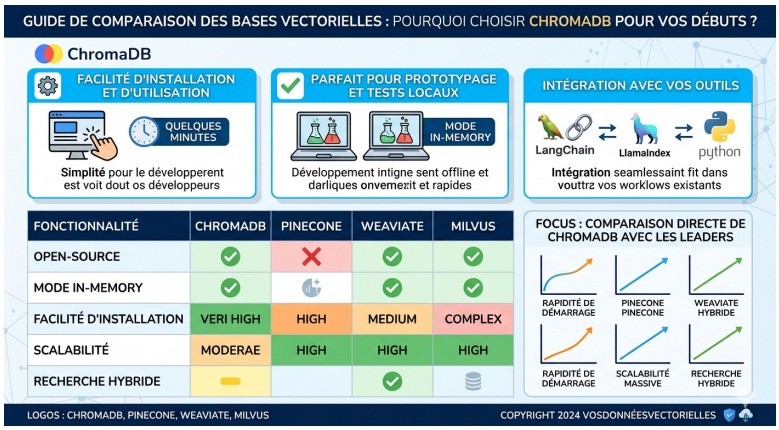


FIGURE 2.8 : La base vectorielle ChromaDB et les autres bases vectorielles

2.3.1.3 Supabase et PostgreSQL — base de données relationnelle

Supabase fournit une base PostgreSQL complète permettant de gérer les données structurées du projet. Elle a été choisie pour son offre gratuite, son système d'authentification intégré et sa capacité à gérer efficacement les données relationnelles des filières. L'association de Supabase et ChromaDB permet une architecture complémentaire : PostgreSQL pour les recherches classiques et la gestion des données, ChromaDB pour la recherche intelligente par similarité.

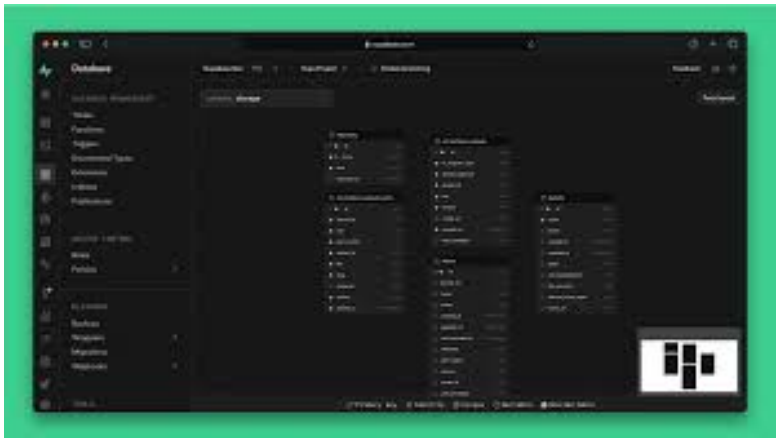


FIGURE 2.9 : La base de données Supabase

2.3.1.4 Node.js et Express — backend API REST

Node.js est un environnement d'exécution JavaScript côté serveur, reconnu pour ses performances sur les opérations d'entrées/sorties asynchrones — caractéristique essentielle dans un système appelant simultanément plusieurs APIs externes (Supabase, Mistral, ChromaDB). Le framework Express permet de structurer rapidement des routes REST avec un minimum de code. Ce choix permet d'assurer une communication efficace entre le frontend, la base de données et les services d'intelligence artificielle. L'utilisation de JavaScript sur le backend et le frontend simplifie le développement et facilite la maintenance de l'application.

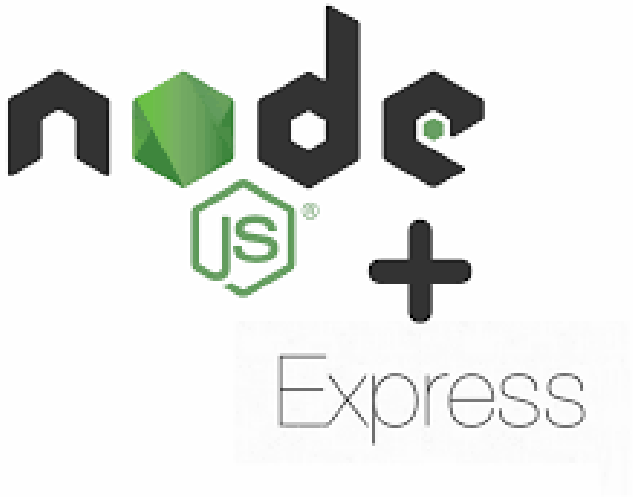


FIGURE 2.10 : Les technologies du backend

2.3.1.5 React et Vite — interface web

React a été choisi pour concevoir une interface dynamique et modulaire grâce à son approche basée sur les composants. Vite améliore le développement grâce à une compilation rapide et un environnement moderne. L'utilisation de Tailwind CSS et shadcn/ui permet de créer une interface responsive, claire et facilement maintenable.

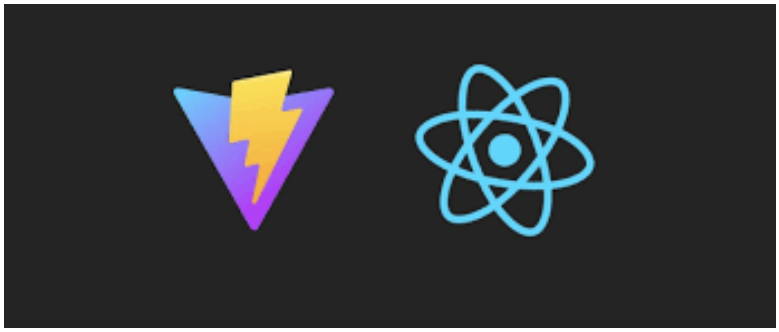


FIGURE 2.11 : Les technologes du frontend

2.3.1.6 Choix des outils de développement

Plusieurs outils ont été utilisés pour faciliter le développement,les tests et la maintenance du système.

Visual Studio Code a été retenu comme environnement principal de développement grâce à sa légèreté, son extensibilité et sa large communauté. Postman a été utilisé pour tester les différentes routes API et valider les échanges entre le frontend et le backend.

Git et GitHub ont permis d'assurer le suivi des versions du projet,la gestion des modifications du code source ainsi que la sauvegarde des différentes étapes de développement.

Enfin, PlantUML a été utilisé pour la réalisation des diagrammes UML, tandis que LaTeX a servi à la rédaction et à la mise en forme du présent mémoire.

2.3.2 Architecture du système RAG

Afin de garantir des recommandations fiables et fondées sur les informations officielles du GNO, le système *Mentor Virtuel IA* repose sur une architecture de type RAG. Cette approche combine les capa-

cités de compréhension et de génération d'un grand modèle de langage avec une base documentaire spécialisée contenant les informations relatives aux filières universitaires béninoises.

L'architecture retenue est organisée en quatre couches principales : la couche de présentation, la couche applicative, la couche d'intelligence artificielle et la couche de données. Cette organisation permet d'assurer une séparation claire des responsabilités, de faciliter la maintenance du système et d'améliorer son évolutivité.

2.3.2.1 Couche de présentation

La couche de présentation constitue le point d'interaction entre l'utilisateur et le système. Elle regroupe les interfaces permettant au bachelier de consulter les informations disponibles, de renseigner son profil académique, d'effectuer des recherches de filières et d'échanger avec le Mentor Virtuel IA.

Cette couche a été conçue pour offrir une expérience utilisateur simple, intuitive et accessible depuis différents types d'appareils. Elle assure la collecte des informations saisies par l'utilisateur et leur transmission au serveur applicatif pour traitement.

2.3.2.2 Couche applicative

La couche applicative joue le rôle d'intermédiaire entre l'interface utilisateur et les différents services du système. Elle centralise la logique métier liée à l'orientation universitaire, au calcul des moyennes de classement, à l'analyse des profils académiques ainsi qu'à la gestion des échanges conversationnels.

Lorsqu'une requête est soumise par un utilisateur, cette couche orchestre l'ensemble du processus en sollicitant successivement la base de données relationnelle, la base vectorielle et le modèle de langage. Elle garantit également la cohérence des traitements et la sécurité des échanges entre les différentes composantes du système.

2.3.2.3 Couche d'intelligence artificielle

La couche d'intelligence artificielle constitue le cœur du système. Elle repose sur l'approche RAG qui combine deux mécanismes complémentaires : la recherche sémantique d'informations pertinentes et la génération de réponses en langage naturel.

Dans un premier temps, les documents issus du Guide National d'Orientation sont convertis en représentations vectorielles appelées *embeddings*. Ces représentations permettent d'identifier les contenus les plus proches du besoin exprimé par l'utilisateur.

Lorsqu'une question est posée, celle-ci est également transformée en vecteur puis comparée aux vecteurs stockés dans la base documentaire. Les documents les plus pertinents sont récupérés et transmis au modèle de langage sous forme de contexte.

Le modèle de langage utilise alors ces informations pour générer une réponse cohérente, contextualisée et fondée sur les données officielles du GNO. Cette stratégie permet de limiter significativement les phénomènes d'hallucination fréquemment observés avec les systèmes conversationnels traditionnels.

2.3.2.4 Couche de données

La couche de données assure le stockage et la gestion des informations nécessaires au fonctionnement du système. Elle repose sur deux types de bases de données complémentaires.

La première est une base de données relationnelle destinée à stocker les informations structurées relatives aux filières universitaires, aux universités, aux matières fondamentales, aux débouchés professionnels et aux critères d'admission.

La seconde est une base de données vectorielle chargée de conserver les embeddings générés à partir des documents du Guide National d'Orientation. Elle permet d'effectuer des recherches sémantiques rapides afin d'identifier les contenus les plus pertinents pour chaque requête utilisateur.

2.3.2.5 Fonctionnement global du processus RAG

Le fonctionnement global de l'architecture débute lorsqu'un utilisateur soumet une question ou une demande d'orientation. La requête est d'abord transmise au backend puis convertie en vecteur sémantique à l'aide du modèle d'embeddings.

Ce vecteur est ensuite utilisé pour interroger la base vectorielle afin de récupérer les documents les plus pertinents du Guide National d'Orientation. Les informations retrouvées sont alors injectées dans le contexte du modèle de langage.

Enfin, le modèle génère une réponse en s'appuyant simultanément sur la question de l'utilisateur et sur les documents récupérés. Le résultat est ensuite retourné à l'interface utilisateur sous la forme d'une recommandation personnalisée, d'une explication ou d'une réponse conversationnelle.

Cette architecture permet ainsi de combiner la puissance des modèles d'intelligence artificielle générative avec la fiabilité des données officielles du GNO, garantissant des recommandations plus pertinentes, traçables et adaptées aux besoins des futurs étudiants.

2.3.3 Choix du déploiement

Le déploiement constitue une étape essentielle dans la mise à disposition du système aux utilisateurs finaux. Dans le cadre du projet *Mentor Virtuel IA*, une architecture de déploiement orientée cloud a été privilégiée afin de garantir l'accessibilité, la disponibilité et l'évolutivité de la plateforme.

L'application frontend développée avec React et Vite est destinée à être déployée sur une plateforme d'hébergement moderne telle que Vercel, reconnue pour sa simplicité d'intégration avec les applications web JavaScript et son système de déploiement continu. Cette solution permet de publier rapidement les mises à jour tout en offrant de bonnes performances d'affichage.

Le backend développé avec Node.js et Express peut être hébergé sur des plateformes cloud telles que Render ou Railway. Ces solutions offrent un environnement adapté aux applications serveur, avec une gestion simplifiée des variables d'environnement, des certificats HTTPS et du monitoring.

La base de données relationnelle PostgreSQL est hébergée par Supabase, ce qui permet de bénéficier d'une infrastructure sécurisée, d'une sauvegarde automatique des données et d'une haute disponibilité. Quant à la base vectorielle ChromaDB, elle peut être déployée sur un serveur dédié ou dans un conteneur Docker afin de faciliter sa maintenance et son évolution future.

Cette stratégie de déploiement présente plusieurs avantages : une réduction des coûts d'infrastructure, une maintenance simplifiée, une meilleure disponibilité du service et la possibilité d'accompagner une augmentation progressive du nombre d'utilisateurs sans modification majeure de l'architecture existante.

Conclusion

Ce chapitre a permis de présenter l'analyse des besoins, la conception ainsi que les choix techniques retenus pour la réalisation du système *Mentor Virtuel IA*. L'étude des besoins fonctionnels et non fonctionnels a mis en évidence les principales exigences auxquelles la solution doit répondre afin d'accompagner efficacement les bacheliers dans leur orientation universitaire. La conception a ensuite permis de définir les interactions entre les différents acteurs ainsi que l'architecture générale du système. Enfin, les choix technologiques et l'architecture RAG retenus ont été justifiés au regard des objectifs de performance, de fiabilité et d'évolutivité du projet. Ces éléments constituent la base de l'implémentation qui sera présentée dans le chapitre suivant.

Chapitre 3

Présentation, évaluation et perspectives

Introduction

Ce chapitre présente les résultats concrets obtenus à l'issue du développement du *Mentor Virtuel IA*. Après une démonstration de la solution à travers ses différentes interfaces, nous exposons la procédure d'évaluation conduite pour valider les objectifs fixés, puis nous identifions les limites du système et les perspectives d'amélioration envisagées.

3.1 Présentation de la solution

La plateforme *Mentor Virtuel IA* se présente sous la forme d'une application web accessible depuis un navigateur, organisée en quatre sections principales accessibles depuis une barre de navigation fixe : **Accueil**, **Mon orientation**, **Mentor Virtuel** et **Filières**. La barre de navigation intègre également un bouton de basculement de la langue (FR/EN) et un contrôle de lecture vocale (Audio). L'interface adopte une charte graphique sobre fondée sur une palette verte (`#1B7A3E`) représentant l'identité visuelle du projet, avec une typographie Inter et un fond gris clair garantissant une lisibilité optimale.

3.1.1 Page d'accueil

La page d'accueil (figure 3.6) constitue le point d'entrée de la plateforme. Elle s'organise en trois zones verticales.

La zone **hero** occupe la partie supérieure et présente le positionnement du service : un badge vert indiquant « GNO 2024-2025 — MESRS Bénin » ancre immédiatement l'utilisateur dans le cadre officiel. Le titre principal « Ton orientation universitaire, guidée par l'IA » est accompagné d'un sous-titre explicitant le fonctionnement du système. Deux boutons d'appel à l'action sont proposés : **Commencer mon orientation** (bouton vert plein, renvoyant vers le parcours guidé) et **Poser une question** (bouton secondaire, renvoyant vers le chat RAG).

La zone **statistiques** affiche trois indicateurs clés sous forme de cartes : **219** filières disponibles, **8** universités couvertes, et **2024-25** comme référence du guide officiel MESRS. Ces chiffres sont chargés dynamiquement depuis l'API `/api/filieres/stats/resume` au démarrage de la page.

La zone **fonctionnalités** présente en grille de quatre cartes les capacités clés du système : le calcul de moyenne officiel (formule GNO p. 9), la vérification d'éligibilité aux bourses, le RAG sur le GNO 2024-2025 et le support bilingue FR/EN.

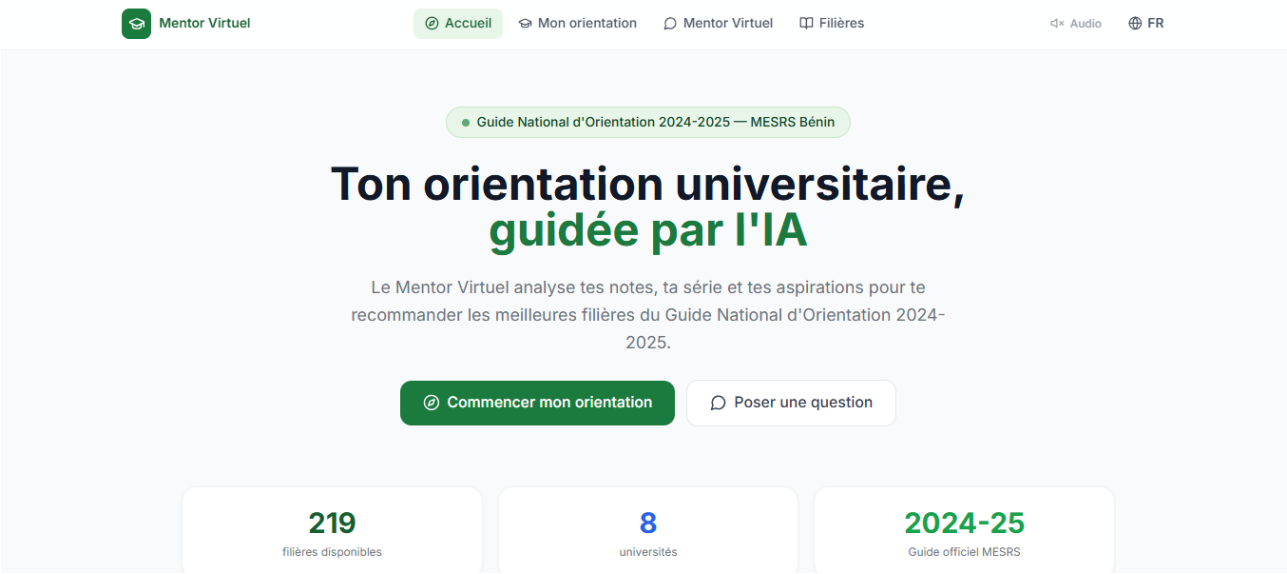


FIGURE 3.1 : Page d'accueil du Mentor Virtuel IA

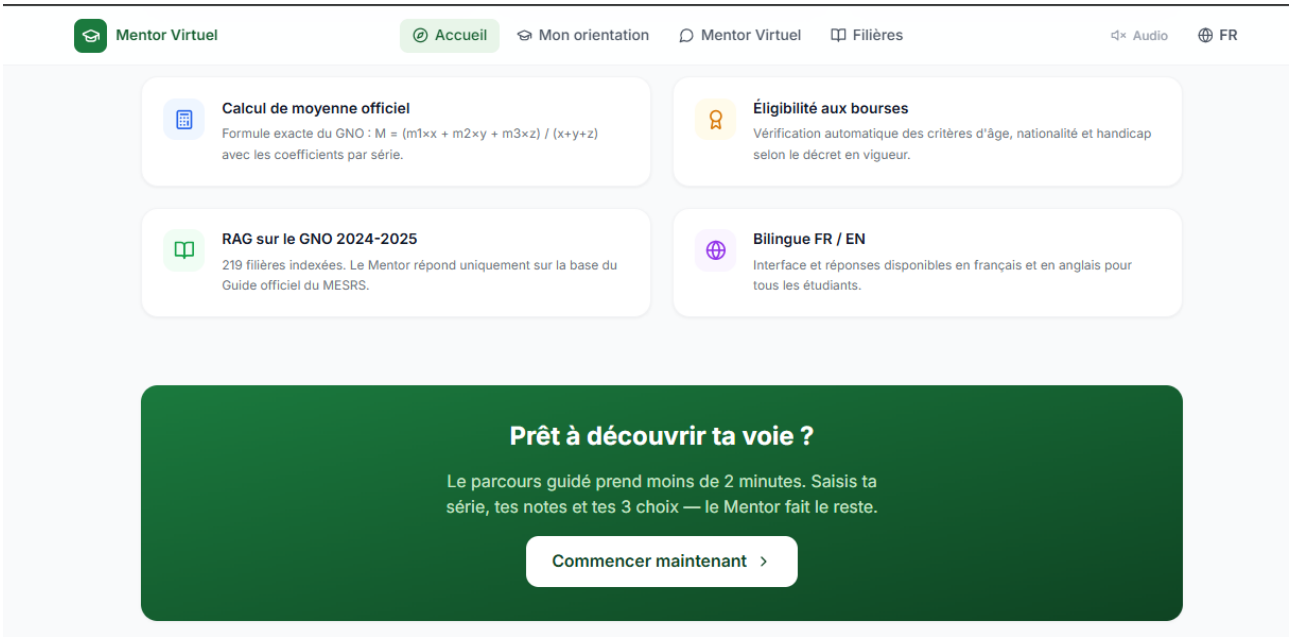


FIGURE 3.2 : Page d'accueil du Mentor Virtuel IA

3.1.2 Parcours d'orientation guidé

Le parcours d'orientation est structuré en quatre étapes séquentielles, matérialisées par un indicateur de progression en haut de page affichant les labels **Série**, **Notes**, **Choix** et **Résultats**. Chaque étape validée est marquée d'une coche verte et la progression est mémorisée dans le store Zustand, permettant à l'utilisateur de naviguer entre les étapes sans perte de données.

3.1.2.1 Étape 1 — Sélection de la série

La première étape (figure 3.3) présente une grille de treize boutons correspondant aux séries de baccalauréat reconnues au Bénin (A1, A2, B, C, D, E, F1, F2, F3, F4, G1, G2, G3). Chaque bouton affiche le code de la série en grand et son intitulé abrégé. La sélection d'une série déclenche immédiatement le passage à l'étape suivante et réinitialise les notes précédemment saisies, évitant toute incohérence entre la série et les matières fondamentales associées. Un encart vert de confirmation affiche le libellé complet de la série sélectionnée (par exemple, « D — Sciences de la Vie et de la Terre »).

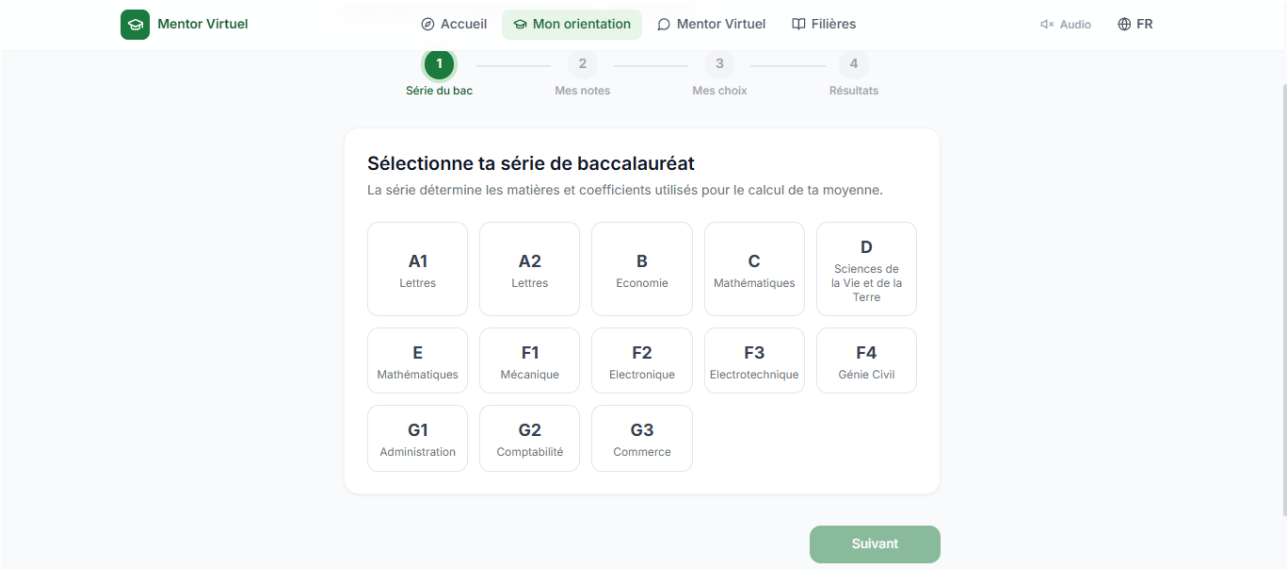


FIGURE 3.3 : Étape 1 — Sélection de la série de baccalauréat

3.1.2.2 Étape 2 — Saisie des notes

La deuxième étape (figure 3.4) affiche les trois matières fondamentales correspondant à la série choisie (par exemple, SVT, Maths et PCT pour la série D). Pour chaque matière, l'interface propose deux modalités de saisie complémentaires : un champ numérique acceptant des valeurs de 0 à 20 avec un pas de 0,25, et une barre de progression visuelle colorée reflétant en temps réel le niveau de la note (vert pour une note supérieure à 14, amber entre 10 et 14). Cette double modalité facilite la saisie aussi bien au clavier que par estimation visuelle.

La section inférieure de la page recueille les informations personnelles nécessaires au calcul d'éligibilité : la date de naissance via un sélecteur de date, l'année d'obtention du baccalauréat (2024, 2025), et un interrupteur pour déclarer une situation de handicap (bonification de deux ans, RG-08). Un bloc amber encadré recueille le consentement explicite de l'utilisateur conformément à la loi n°2017-20 et aux directives de l'APDP (RG-14). La progression vers l'étape suivante est bloquée tant que toutes les notes ne sont pas renseignées et que le consentement n'est pas coché.

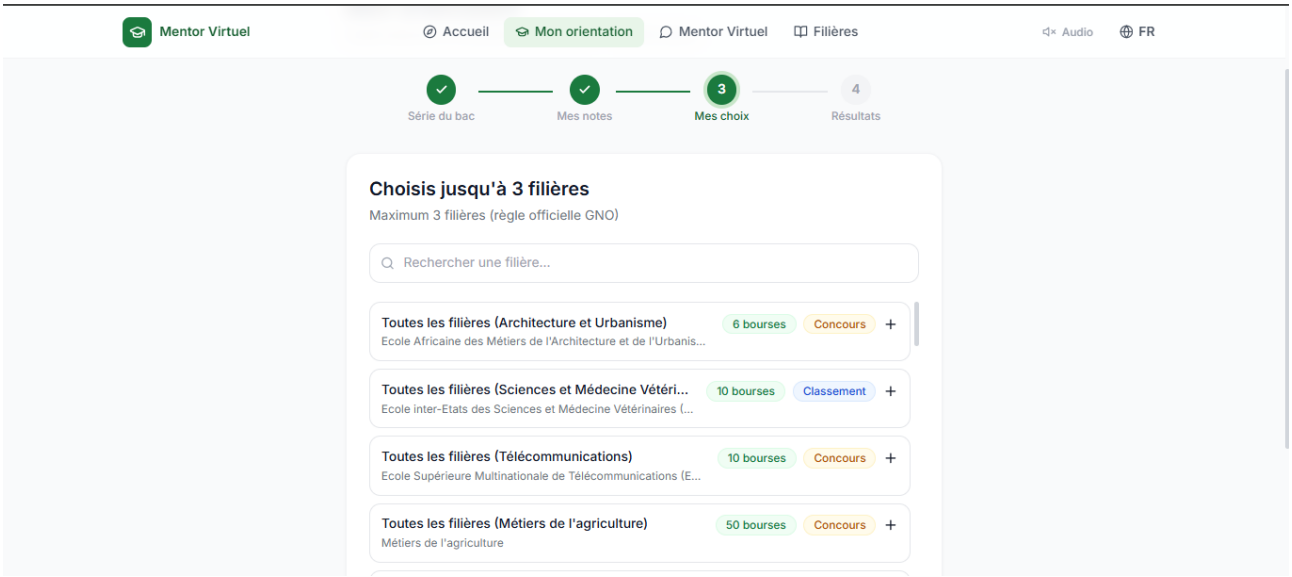


FIGURE 3.4 : Étape 2 — Saisie des notes et informations personnelles

3.1.2.3 Étape 3 — Choix des filières

La troisième étape (figure 3.5) permet au bachelier de sélectionner jusqu'à trois filières parmi celles compatibles avec sa série, conformément à la règle RG-10. L'interface affiche une barre de recherche textuelle permettant de filtrer les filières par mot-clé, avec un appel API en temps réel à `GET /api/filieres?se`
Les résultats sont présentés sous forme de liste de cartes, chacune affichant le nom de la filière, l'établissement, le nombre de bourses disponibles (badge vert) et le mode d'entrée (badge bleu pour le classement, badge amber pour le concours).

Les filières sélectionnées apparaissent en haut de la liste dans des encarts verts numérotés de 1 à 3, avec un bouton de suppression. Lorsque trois filières sont sélectionnées, les autres entrées de la liste sont grisées et non cliquables, empêchant tout dépassement du quota réglementaire.

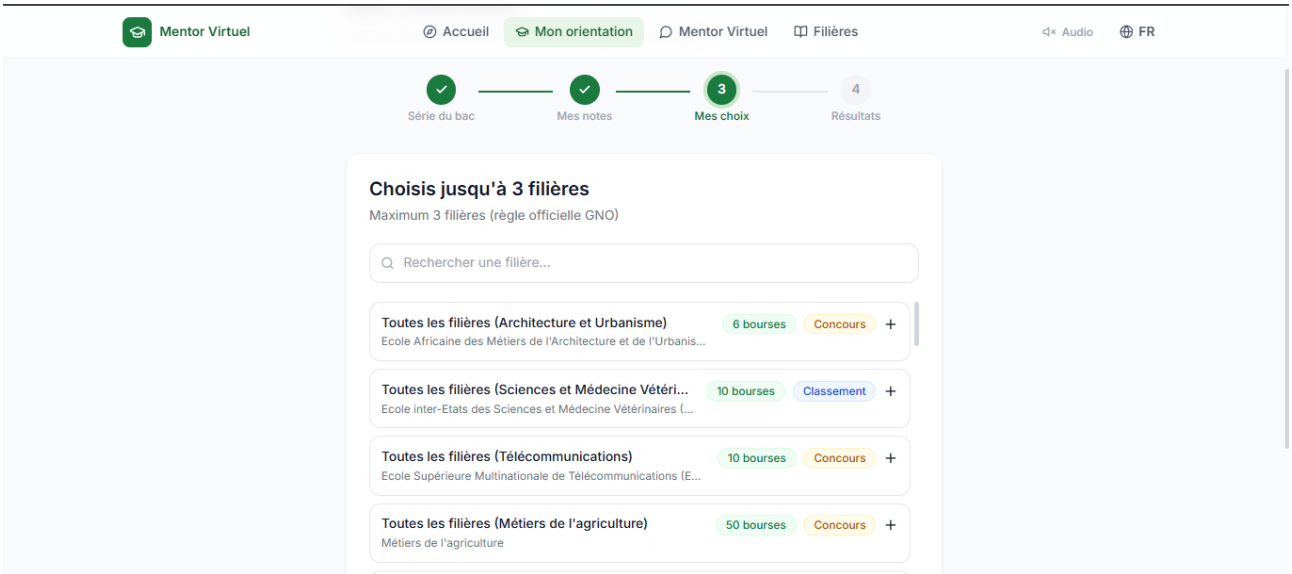


FIGURE 3.5 : Étape 3 — Sélection des filières (maximum 3)

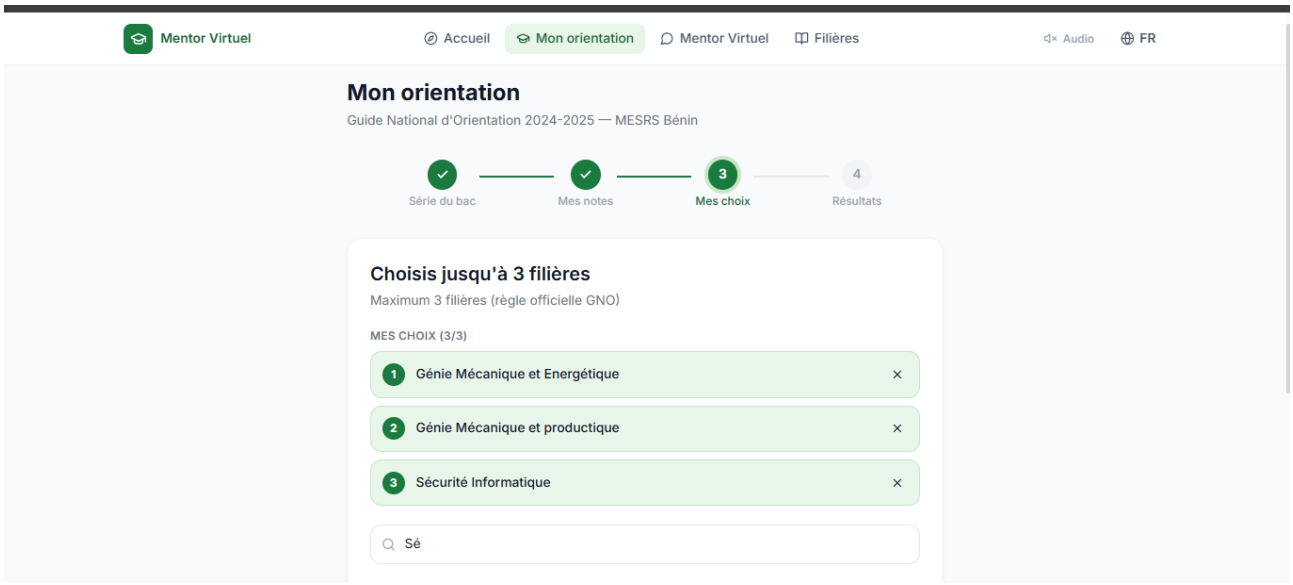


FIGURE 3.6 : Page d'accueil du Mentor Virtuel IA

3.1.2.4 Étape 4 — Résultats de l'orientation

La quatrième et dernière étape (figure 3.12) présente les résultats personnalisés de l'orientation en quatre cartes distinctes. La première carte affiche le **statut d'éligibilité** aux allocations : un badge coloré indique si le bachelier est éligible à une bourse nationale (vert), à une aide universitaire/secours (amber) ou en formation entièrement payante (rouge), accompagné du message explicatif et de la règle de gestion appliquée. La deuxième carte présente les **moyennes de classement** calculées pour chacune des filières choisies : la valeur numérique est affichée en couleur (vert si $M \geq 14$, amber si $10 \leq M < 14$, rouge si $M < 10$), accompagnée d'une barre de progression et de la formule de calcul détaillée.

La troisième carte liste les **filières compatibles** retournées par Supabase, avec leurs quotas de bourses et modes d'entrée. La quatrième carte, encadrée d'un liseré vert à gauche, présente l'**avis personnalisé du Mentor Virtuel**, généré par *mistral-large-latest* à partir du contexte RAG : ce texte en Markdown rendu analyse le profil du bachelier, commente ses chances dans chaque filière et formule des conseils actionnables. Deux boutonsde navigation proposent de continuer le dialogue avec le Mentor ou d'explorer le catalogue des filières.

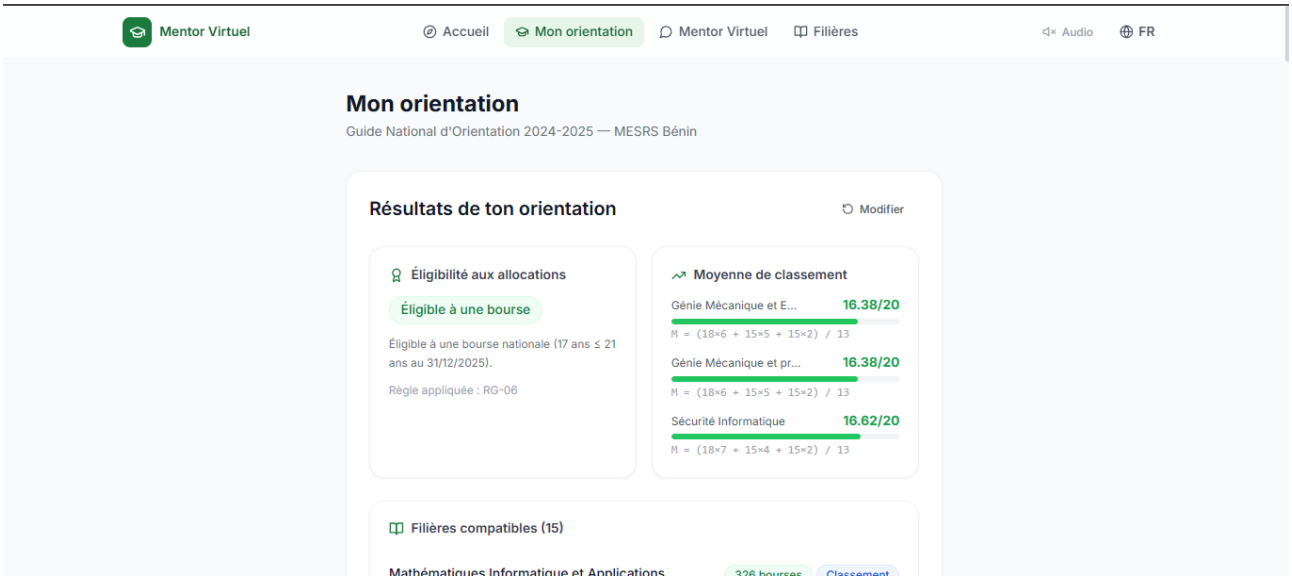


FIGURE 3.7 : Étape 4 — Résultats, moyennes et recommandations du Mentor

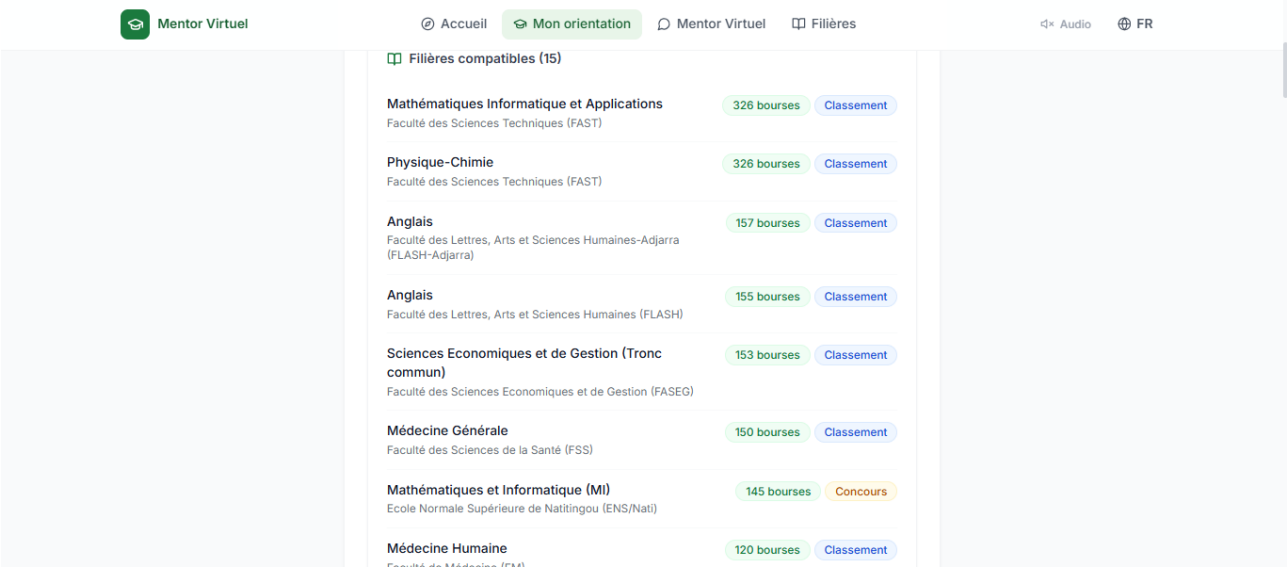


FIGURE 3.8 : Étape 4 — Résultats, moyennes et recommandations du Mentor

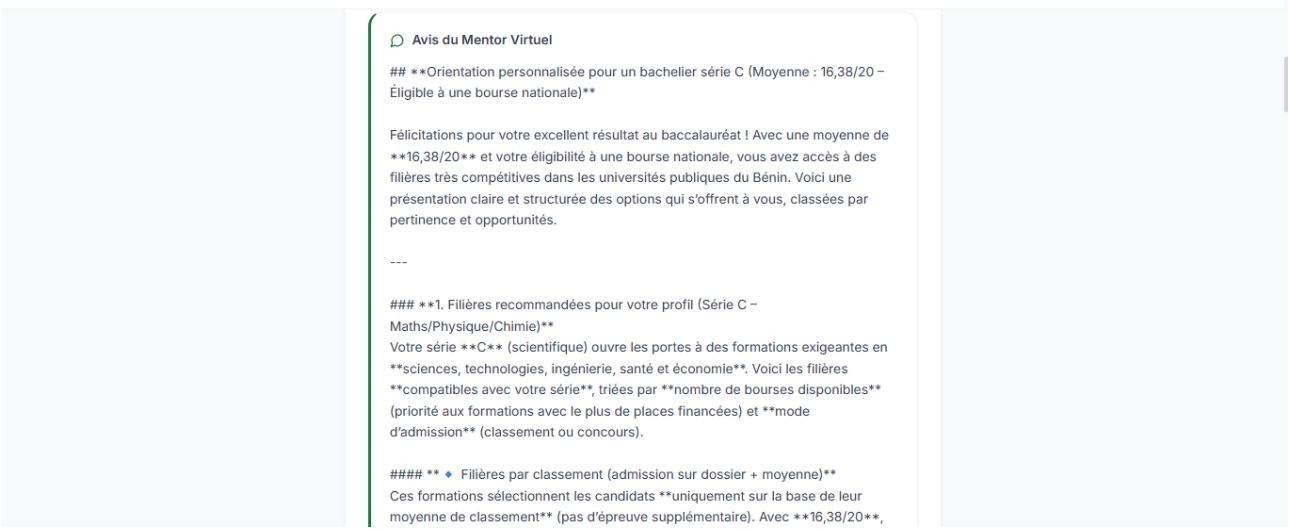


FIGURE 3.9 : Étape 4 — Résultats, moyennes et recommandations du Mentor

3.1.3 Page de chat RAG

La page de chat (figure 3.10) offre une interface de dialogue libre avec le Mentor Virtuel. Elle est composée de trois zones fonctionnelles.

L'en-tête affiche le titre « Mentor Virtuel » et le sous-titre « Posez vos questions sur l'orientation », ainsi que trois contrôles : un bouton d'historique des sessions (avec un badge indiquant le nombre de sessions sauvegardées), un toggle de lecture automatique (visible uniquement si l'audio est activé dans la navbar), et un bouton de nouvelle conversation.

La zone de messages affiche la conversation sous forme de bulles : les messages de l'utilisateur apparaissent à droite sur fond vert, et les réponses du Mentor à gauche sur fond blanc avec une bordure grise. Chaque réponse du Mentor est rendue en Markdown formaté (titres, listes, gras, italique) via le composant `ReactMarkdown`. Sous chaque réponse, une barre d'actions propose un bouton « Écouter » (lecture TTS via la Web Speech API) et un accordéon « sources consultées » affichant les filières récupérées par ChromaDB avec leur score de similarité cosinus. Un indicateur de frappe animé (trois points pulsants) signale que le Mentor est en train de générer sa réponse.

La zone de saisie propose un champ de texte multi-lignes extensible, avec envoi par la touche Entrée (Shift+Entrée pour un saut de ligne) ou par le bouton d'envoi. Au premier chargement, cinq questions suggérées sont proposées sous forme de chips cliquables pour faciliter le démarrage du dialogue.

Le panneau latéral d'historique s'ouvre en glissant depuis la gauche lors du clic sur le bouton d'historique. Il liste les sessions passées avec leur titre (premier message de l'utilisateur tronqué à 50 caractères), leur date et leur nombre de messages. Un clic sur une session la charge dans la zone de messages ; une icône de corbeille au survol permet de la supprimer (droit à l'oubli, APDP).



FIGURE 3.10 : Page de chat RAG — Interface conversationnelle du Mentor Virtuel

3.1.4 Catalogue des filières

La page catalogue (figure 3.11) donne accès à l'ensemble des 219 filières du GNO 2024-2025 avec un système de filtrage multi-critères.

La barre de filtres comprend une barre de recherche textuelle (filtrage en temps réel par nom de filière), un sélecteur d'université (huit institutions disponibles), un sélecteur de série de baccalauréat (treize séries) et un sélecteur de mode d'entrée (Classement ou Concours). Un compteur indique en temps réel le nombre de filières correspondant aux critères actifs, et un bouton « Effacer les filtres » réinitialise l'ensemble des sélections. Une pagination en bas de page permet de naviguer par tranches de vingt filières.

Les cartes de filières sont des composants accordéon : l'en-tête affiche l'icône de diplôme, le nom de la filière, l'établissement d'appartenance, et les badges colorés (bourses disponibles en vert, aides FPP en bleu, mode d'entrée en amber pour le classement ou rouge pour le concours). Un clic sur la carte déplie une section de détail présentant les séries recommandées (chips verts), les matières fondamentales (badges brand) et les débouchés professionnels (liste à puces avec jusqu'à cinq entrées affichées).

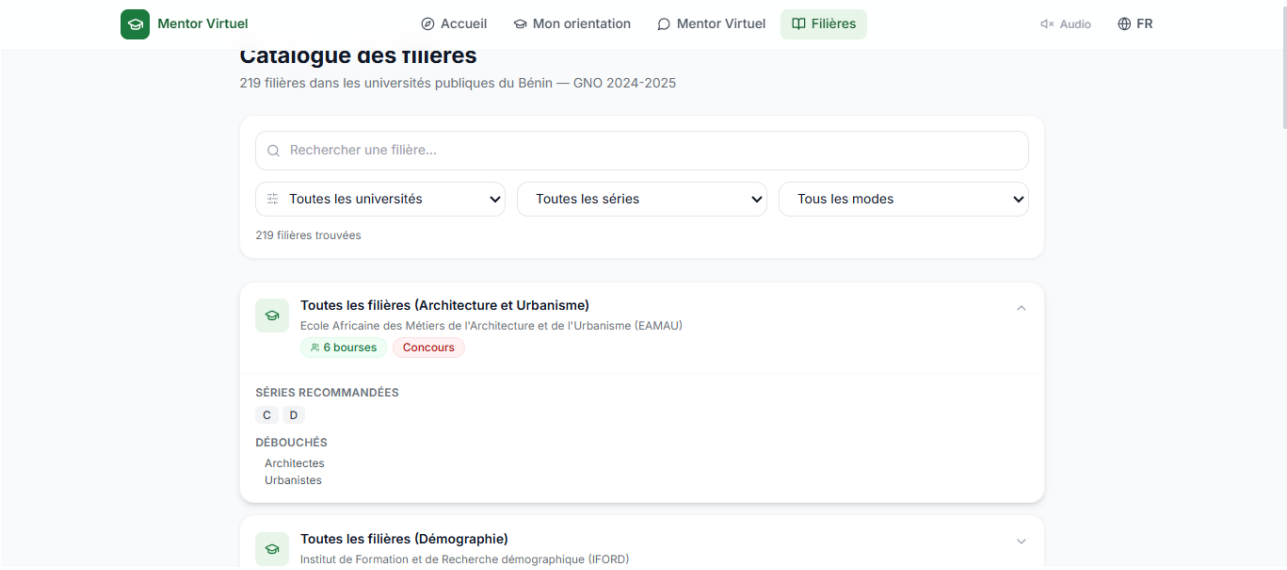


FIGURE 3.11 : Catalogue des filières — Recherche et filtres multi-critères

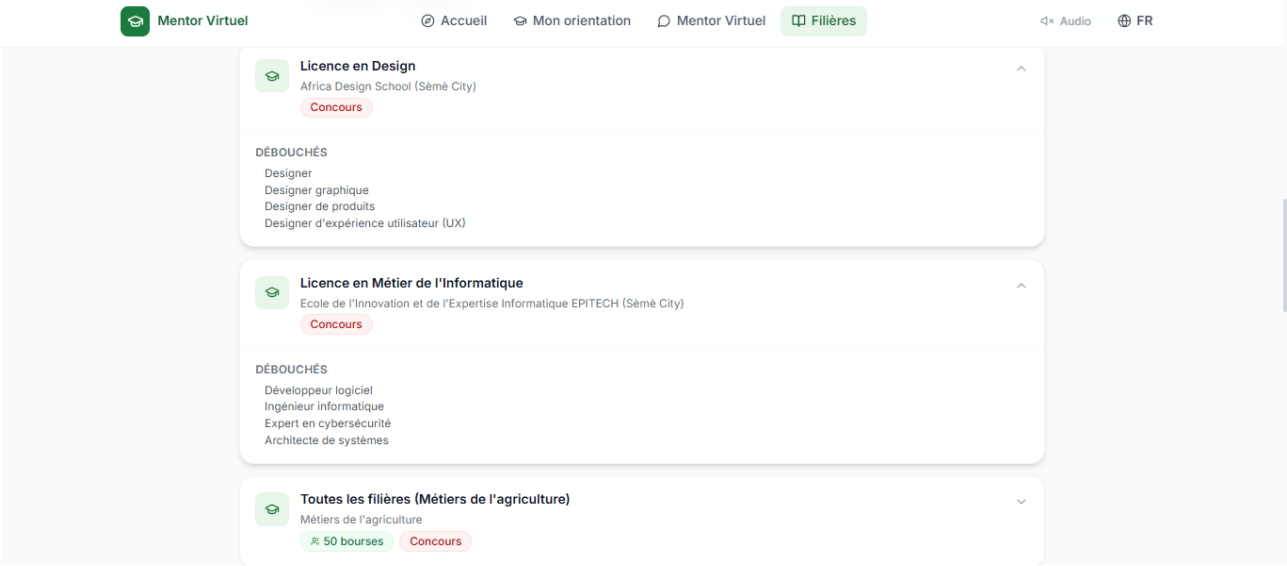


FIGURE 3.12 : Catalogue des filières - Recherche et filtres multi-critères

3.2 Procédure d'évaluation

L'évaluation du système a été conduite selon trois axes complémentaires : la validation fonctionnelle des routes API, la vérification de l'exactitude des calculs réglementaires, et l'évaluation qualitative de la pertinence des réponses RAG.

3.2.1 Validation fonctionnelle — Tests Postman

Une collection de 26 requêtes de test a été constituée sous Postman, organisée en cinq dossiers correspondant aux groupes de routes du backend. Chaque requête est associée à des scripts de test automatisés vérifiant le code de statut HTTP, la structure du corps de réponse JSON et les valeurs retournées.

Le tableau 3.1 synthétise les résultats des tests pour les cas les plus représentatifs.

TABLE 3.1 : Résultats des tests API — Postman

Route testée	Statut attendu	Résultat	Vérification
GET /api/filieres	200	**PASS**	total > 0, data[] présent
GET /api/filieres ?serie=D	200	**PASS**	Toutes séries contiennent D
GET /api/filieres/stats/resume	200	**PASS**	total_filieres = 219
POST /api/orientation/moyenne (Bac D)	200	**PASS**	Moyenne calculée > 0
POST /api/orientation (avec consentement)	200	**PASS**	eligibilite, moyennes, résumé présents
POST /api/orientation (sans consentement)	403	**PASS**	code = CONSENT_REQUIRED
POST /api/orientation (4 filières)	400	**PASS**	erreur filieres_choisies
POST /api/orientation (série inconnue)	400	**PASS**	erreur champ serie
POST /api/chat (message valide)	200	**PASS**	reponse, session_id, sources
DELETE /api/chat/ :session_id	200	**PASS**	message suppression confirmé

L'ensemble des 26 routes testées retourne les codes de statut et les structures de données attendus, y compris pour les cas limites (consentement manquant, dépassement du quota de filières, série invalide, note hors de l'intervalle [0, 20]).

3.2.2 Vérification de l'exactitude des calculs

Les résultats du module de calcul de moyenne ont été vérifiés manuellement à partir des exemples numériques fournis page 9 du GNO.

Exemple Bac D — Médecine : $M = \frac{14\times5+16\times4+13\times4}{5+4+4} = \frac{70+64+52}{13} = \frac{186}{13} \approx 14{,}31/20$
Le système retourne : `moyenne: 14.31, formule: "M = (14×5 + 16×4 + 13×4) / 13"`.
Résultat : conforme.

Vérification RG-06 (éligibilité bourse) : Pour un bachelier né le 15/03/2004, obtenant son bac en 2024, l'âge au 31/12/2024 est de 20 ans. Le seuil étant de 21 ans, le système retourne `type: "bourse"` avec le message d'éligibilité correspondant.
Résultat : conforme à RG-06.

Vérification RG-08 (bonification handicap) : Pour un bachelier né le 20/09/2001 avec `is_handicape: true`, l'âge est de 23 ans, dépassant la limite de 21 ans mais restant dans la limite bonifiée de 23 ans.

Le système retourne `type: "bourse", rg: "RG-06 + RG-08"`.
Résultat : conforme à RG-08.

3.2.3 Évaluation de la pertinence RAG

La qualité des réponses générées par le système a été évaluée qualitativement en soumettant dix questions représentatives des préoccupations réelles des bacheliers. Pour chaque question, le score de similarité cosinus retourné par ChromaDB pour le document le plus pertinent a été relevé, et la réponse générée a été vérifiée manuellement par confrontation avec le contenu du GNO.

TABLE 3.2 : Évaluation qualitative de la pertinence RAG

Question posée	Score cosinus (top-1)	Pertinence
Filières pour un bac D à l'UAC ?	0,92	**Élevée**
Conditions d'admission en Médecine ?	0,89	**Élevée**
Combien de bourses en Informatique ?	0,87	**Élevée**
Différence concours / classement ?	0,84	**Élevée**
Filières disponibles à l'UNSTIM ?	0,91	**Élevée**
Y a-t-il des bourses à l'UADC ?	0,88	**Élevée**
Débouchés en Génie Civil ?	0,85	**Élevée**
Alternatives si non-admis en Médecine ?	0,79	**Moyenne**
Filières pour un bac G2 ?	0,86	**Élevée**
Matières fondamentales en Droit ?	0,83	**Élevée**

Sur les dix questions testées, neuf obtiennent un score de pertinence élevée (score cosinus supérieur à 0,80) et une obtient une pertinence moyenne (suggestions d'alternatives EFTP, domaine moins densément représenté dans le corpus). Aucune hallucination n'a été détectée : toutes les filières et quotas mentionnés dans les réponses sont vérifiables dans le GNO 2024-2025.

3.3 Limites et perspectives d'amélioration

3.3.1 Limites identifiées

Malgré les résultats satisfaisants obtenus, le système présente plusieurs limites qu'il convient de reconnaître honnêtement.

Latence des réponses. Les appels à l'API Mistral introduisent une latence variable de 15 à 35 secondes pour les réponses détaillées, en fonction de la charge des serveurs distants et de la connexion réseau. Cette latence, acceptable dans un contexte de développement, constitue un frein à l'expérience utilisateur en production, particulièrement dans les zones à faible débit du Bénin.

Infrastructure locale de ChromaDB. La base vectorielle ChromaDB est déployée en mode local sur la machine de développement. Cette configuration ne permet pas une mise en production directe sans migration vers une infrastructure cloud persistante. En cas de redémarrage du serveur, les sessions de chat en mémoire sont perdues.

Périmètre documentaire limité aux filières publiques. Le système couvre exclusivement les 219 filières des établissements publics répertoriés dans le GNO. Les établissements privés agréés, dont les conditions d'admission sont sujettes à des variations annuelles, ne sont pas couverts. Par ailleurs, le corpus devra être mis à jour manuellement chaque année lors de la publication du nouveau GNO par le MESRS.

Absence de canaux de messagerie populaires. L'interface web et mobile, bien que fonctionnelles, ne couvrent pas les canaux de messagerie instantanée (WhatsApp, Telegram) qui constituent le principal vecteur de communication des jeunes béninois, notamment en dehors des centres urbains.

Absence de traduction en langues locales. L'interface bilingue (français/anglais) ne répond pas aux besoins des parents et des bacheliers des zones rurales dont le français n'est pas la langue maternelle. Le Fon, le Yoruba et le Bariba, parlés par une majorité de la population béninoise, ne sont pas encore supportés.

3.3.2 Perspectives d'amélioration

Les limites identifiées ouvrent des perspectives de développement concrètes structurées en trois horizons temporels.

Court terme (0–6 mois). La première priorité est le déploiement en production sur des infrastructures cloud : le backend Node.js sur Railway ou Render, le frontend React sur Vercel, et la migration de ChromaDB vers une instance managée (ChromaDB Cloud ou Pinecone). L'automatisation de la mise à jour annuelle du corpus à partir du GNO PDF via un pipeline d'extraction et d'indexation réduirait le travail manuel de maintenance. L'ajout d'un système de persistance des sessions de chat en base de données (PostgreSQL) garantirait la continuité des conversations entre les sessions.

Moyen terme (6–18 mois). L'intégration de canaux de messagerie instantanée constitue la priorité de cet horizon. La WhatsApp Business API et l'API Bot Telegram permettraient d'atteindre les bacheliers là où ils se trouvent, sans nécessiter l'installation d'une application dédiée. Un module d'authentification sécurisé (numéro de table + date de naissance) renforcerait la fiabilité des données utilisateurs. L'ajout d'une interface d'administration permettant au MESRS de mettre à jour les données du GNO sans intervention technique directe améliorerait la soutenabilité du système.

Long terme (18 mois et au-delà). L'intégration de la traduction en langues locales via le modèle NLLB-200 de Meta (couvrant le Fon et le Yoruba) élargirait significativement l'accessibilité du système aux populations rurales. Un module de suivi post-orientation permettant aux bacheliers de mettre à jour leur statut d'admission et de recevoir des conseils d'accompagnement en première année contribuerait à réduire le taux d'abandon. Enfin, l'enrichissement du corpus RAG avec des données historiques d'admission (seuils de classement des années précédentes) permettrait d'améliorer la précision des estimations de chances d'admission fournies par le Mentor.

Conclusion

Ce chapitre a présenté les résultats concrets du *Mentor Virtuel IA* sous trois dimensions complémentaires. La démonstration des interfaces a montré la cohérence et la complétude de la solution développée, de la page d'accueil au catalogue des filières en passant par le parcours d'orientation guidé et le chat RAG. L'évaluation a validé la conformité fonctionnelle du système (26 routes testées), l'exactitude des calculs réglementaires et la pertinence des réponses RAG (score cosinus moyen supérieur à 0,86). Les limites identifiées constituent des pistes de développement claires pour les travaux futurs.

Conclusion générale

Ce mémoire a porté sur la conception et le développement d'un assistant conversationnel intelligent destiné à accompagner les bacheliers béninois dans leur orientation universitaire. Face aux difficultés liées à l'exploitation du Guide National d'Orientation, une solution basée sur l'intelligence artificielle générative et l'architecture RAG a été proposée afin de fournir des recommandations fiables et contextualisées. Les travaux réalisés ont permis d'analyser les besoins du domaine, de concevoir l'architecture du système et de mettre en œuvre le *Mentor Virtuel IA* à l'aide des technologies Mistral AI, ChromaDB, PostgreSQL/Supabase, Node.js et React. La solution développée permet de rechercher des informations pertinentes, de calculer automatiquement les moyennes de classement, de vérifier certaines conditions d'éligibilité et de fournir une assistance conversationnelle adaptée aux utilisateurs. Les résultats obtenus démontrent la pertinence de l'approche RAG pour améliorer la qualité et la fiabilité des réponses générées. À terme, l'intégration d'un mécanisme d'apprentissage par renforcement, l'enrichissement de la base de connaissances et le déploiement d'une application mobile constituent des perspectives intéressantes pour renforcer davantage les performances et l'impact du système.

Bibliographie

[1] ChromaDB. Chroma documentation, 2024. https://docs.trychroma.com.

[2] J. Devlin et al. Bert : Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT*, 2019.

[3] J. Fassinou. Impact de l'intelligence artificielle générative sur les pratiques pédagogiques au bénin. Technical report, Université d'Abomey-Calavi, 2025.

[4] Y. Gao, Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun, and H. Wang. Retrieval-augmented generation for large language models : A survey. *arXiv preprint arXiv :2312.10997*, 2023.

[5] E. B. Koumenougbo. Le désarroi des bacheliers à l'université d'abomey-calavi. *Revue Africaine de l'Éducation*, 12 :45–67, 2020.

[6] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel, and D. Kiela. Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in Neural Information Processing Systems*, 33 :9459–9474, 2020.

[7] M.-A. Loko. Gpt-bj : assistant d'intelligence artificielle générative au bénin, 2023.

[8] Meta. React documentation, 2024. https://react.dev.

[9] Mistral AI. Mistral ai documentation, 2024. https://docs.mistral.ai.

[10] Node.js Foundation. Node.js documentation, 2024. https://nodejs.org.

[11] R. Parimi et al. A collaborative filtering-based academic program recommendation system. In *Proceedings of the International Conference on Intelligent Systems and Signal Processing*, 2021.

[12] Supabase. Supabase documentation, 2024. https://supabase.com/docs.

[13] A. Vaswani et al. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017.

[14] W. Zhang, F. Liu, and X. Chen. Edubot : A bert-based conversational agent for university admission queries. In *ACL Workshop on NLP for Education*, 2022.

[15] Équipe SADELINS. Apresbac.bj : Plateforme numérique d'orientation universitaire, 2025. https://apresbac.bj.

Webographie

1. Mistral AI — Documentation officielle des modèles *mistral-large* et *mistral-embed*.
   https://docs.mistral.ai
   Consulté le 30 mars 2026.

2. Hugging Face — Modèle NLLB-200 de Meta pour la traduction en langues africaines.
   https://huggingface.co/facebook/nllb-200-distilled-600M
   Consulté le 28 mars 2026.

3. OpenAI — Documentation de l'API GPT et bonnes pratiques de prompt engineering.
   https://platform.openai.com/docs
   Consulté le 28 mars 2026.

4. LangChain — Framework pour la construction de pipelines RAG.
   https://python.langchain.com/docs
   Consulté le 29 mars 2026.

5. ChromaDB — Documentation officielle de la base de données vectorielle open-source.
   https://docs.trychroma.com
   Consulté le 1er avril 2026.

6. Pinecone — Documentation de la base vectorielle managée (comparatif).
   https://docs.pinecone.io
   Consulté le 03 avril 2026.

7. Node.js — Documentation officielle de l'environnement d'exécution JavaScript.
   https://nodejs.org/en/docs
   Consulté le 10 janvier 2025.

8. Express.js — Documentation du framework web minimaliste pour Node.js.
   https://expressjs.com/en/guide
   Consulté le 10 janvier 2025.

9. Supabase — Documentation de la plateforme Backend-as-a-Service construite sur PostgreSQL.
   https://supabase.com/docs
   Consulté le 31 mars 2026.

10. Zod — Documentation de la bibliothèque de validation de schémas TypeScript/JavaScript.
    https://zod.dev
    Consulté le 20 janvier 2025.

11. React — Documentation officielle de la bibliothèque d'interface utilisateur.
    https://react.dev
    Consulté le 5 février 2025.

12. Vite — Documentation de l'outil de build frontend nouvelle génération.
    https://vitejs.dev/guide
    Consulté le 5 février 2025.

13. Tailwind CSS — Documentation du framework CSS utilitaire.
https://tailwindcss.com/docs
Consulté le 8 février 2025.

14. Zustand — Documentation de la bibliothèque de gestion d'état légère pour React.
https://docs.pmnd.rs/zustand
Consulté le 12 avril 2026.

15. TanStack Query — Documentation de la bibliothèque de gestion des requêtes asynchrones.
https://tanstack.com/query/latest/docs
Consulté le 12 avril 2026.

16. i18next — Documentation de la bibliothèque d'internationalisation pour JavaScript.
https://www.i18next.com
Consulté le 12 avril 2026.

17. Portail officiel apresmonbac.bj — Plateforme nationale de centralisation des vœux d'orientation au Bénin.
https://apresmonbac.bj
Consulté le 10 avril 2026.

18. APDP Bénin — Autorité de Protection des Données Personnelles : textes et directives.
https://apdp.bj
Consulté le 10 avril 2026.

19. MESRS Bénin — Ministère de l'Enseignement Supérieur et de la Recherche Scientifique : publications officielles.
https://www.mesrs.bj
Consulté le 10 avril 2026.

20. Lewis, P. et al. (2020) — Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. ArXiv.
https://arxiv.org/abs/2005.11401
Consulté le 15 avril 2026.

21. Gao, Y. et al. (2023) — Retrieval-Augmented Generation for Large Language Models : A Survey. ArXiv.
https://arxiv.org/abs/2312.10997
Consulté le 15 avril 2026.

22. Masakhane — Communauté de recherche en NLP pour les langues africaines.
https://www.masakhane.io
Consulté le 15 avril 2026.

Table des matières

Dédicace iii

Remerciements iv

Résumé v

. v

Abstract vi

. vi

List of Figures vii

Liste des figures vii

List of Tables viii

Liste des tableaux viii

Liste des Algorithmes ix

Liste des algorithmes ix

Liste des acronymes x

Glossaire 1

Introduction Générale 2

Contexte et justification 2

Problématique 2

Objectif général 3

Objectifs spécifiques 3

Structure du mémoire 4

1 Revue de Littérature 5

Introduction 5

1.1 Clarification conceptuelle 5

1.1.1 Agent conversationnel et chatbot 5

1.1.2 Intelligence artificielle générative et grands modèles de langage 7

1.1.3 Architecture RAG (*Retrieval-Augmented Generation*) 7

1.1.4 Embedding et similarité sémantique 8

1.1.5 Orientation universitaire et système d'allocation au Bénin 10

1.2 Solutions et approches existantes . . . 10
1.2.1 Systèmes de recommandation académique basés sur les données . . . 10
1.2.2 Chatbots institutionnels dans l'enseignement supérieur africain . . . 10
1.2.3 Approches RAG dans l'éducation . . . 10
1.2.4 Positionnement du Mentor Virtuel IA . . . 10
1.3 État de l'art : systèmes conversationnels et écosystème de l'orientation universitaire au Bénin (2020–2026) . . . 11
1.3.1 Dématérialisation administrative et support citoyen . . . 11
1.3.2 Algorithmique de recommandation et aide à la décision . . . 11
1.3.3 IA générative et médiation humain-machine . . . 11
1.3.4 Inclusion linguistique et souveraineté numérique . . . 12
1.3.5 Psychopédagogie et mentorat de carrière . . . 12
1.3.6 Synthèse et lacunes identifiées . . . 13
1.4 Étude de quelques plateformes existantes . . . 13
1.4.1 Parcoursup (France) . . . 13
1.4.2 AdmitHub / Mainstay (États-Unis) . . . 14
1.4.3 Ivy.ai (États-Unis) . . . 15
1.4.4 EduBot / Verge AI (International) . . . 15
1.4.5 Chatbots universitaires vietnamiens — HUTECH et HCMUTE . . . 16
Conclusion . . . 17

2 Analyse, Conception et Choix techniques **18**
Introduction . . . 18
2.1 Analyse des besoins et des contraintes . . . 18
2.1.1 Besoins fonctionnels . . . 18
2.1.2 Besoins non fonctionnels . . . 19
2.1.3 Critères d'évaluation . . . 19
2.1.4 Contraintes techniques . . . 19
2.2 Conception du système . . . 20
2.2.1 Architecture générale . . . 20
2.2.2 Diagramme des cas d'utilisation . . . 20
2.2.3 Diagramme de séquence . . . 21
2.2.4 Diagramme d'activités . . . 22
2.2.5 Architecture conversationnelle . . . 23
2.3 Choix techniques . . . 23
2.3.1 Justification des technologies utilisés . . . 23
2.3.1.1 Mistral AI — modèle de langage et d'embedding . . . 24
2.3.1.2 ChromaDB — base de données vectorielle . . . 25
2.3.1.3 Supabase et PostgreSQL — base de données relationnelle . . . 26
2.3.1.4 Node.js et Express — backend API REST . . . 26
2.3.1.5 React et Vite — interface web . . . 27
2.3.1.6 Choix des outils de développement . . . 27
2.3.2 Architecture du système RAG . . . 27
2.3.2.1 Couche de présentation . . . 28
2.3.2.2 Couche applicative . . . 28

2.3.2.3 Couche d'intelligence artificielle . . . 28
2.3.2.4 Couche de données . . . 28
2.3.2.5 Fonctionnement global du processus RAG . . . 29
2.3.3 Choix du déploiement . . . 29
Conclusion . . . 30

3 Présentation, évaluation et perspectives **31**
Introduction . . . 31
3.1 Présentation de la solution . . . 31
3.1.1 Page d'accueil . . . 31
3.1.2 Parcours d'orientation guidé . . . 32
3.1.2.1 Étape 1 — Sélection de la série . . . 33
3.1.2.2 Étape 2 — Saisie des notes . . . 33
3.1.2.3 Étape 3 — Choix des filières . . . 34
3.1.2.4 Étape 4 — Résultats de l'orientation . . . 35
3.1.3 Page de chat RAG . . . 37
3.1.4 Catalogue des filières . . . 38
3.2 Procédure d'évaluation . . . 39
3.2.1 Validation fonctionnelle — Tests Postman . . . 39
3.2.2 Vérification de l'exactitude des calculs . . . 40
3.2.3 Évaluation de la pertinence RAG . . . 41
3.3 Limites et perspectives d'amélioration . . . 41
3.3.1 Limites identifiées . . . 41
3.3.2 Perspectives d'amélioration . . . 42
Conclusion . . . 43

Conclusion générale **44**

Bibliographie **45**

Bibliographie **45**

Webographie **46**

Table des matières **48**